01 EL MAPA

Del CSV a las respuestas

Una fila representa una inspección. Un establecimiento puede tener muchas inspecciones.

316.961
registros

17
columnas

1 fila
una inspección

12 consultas ejecutadas en Oracle.
Limpieza pendiente de aprobación.

1 **CSV**
original
CONSERVADO

→

2 **Tabla RAW**
en Oracle
CARGADA

→

3 **Perfilado**
calidad revisada
EJECUTADO

→

4 **Limpieza**
transformar
PENDIENTE

→

5 **Datos**
preparados
PENDIENTE

→

6 **Analytics**
analizar
PENDIENTE

→

7 **Science**
modelar
PENDIENTE

RAW = FOOD_INSPECTIONS_RAW · El CSV se conserva · El perfilado usa solo SELECT

Engineering

RECIBE
CSV original

ENTREGA ESPERADA
Datos preparados + evidencia

Salida práctica aún pendiente

Analytics

RECIBE
Datos preparados

ENTREGA ESPERADA
Indicadores + interpretación

Salida práctica aún pendiente

Science

RECIBE
Datos preparados + pregunta

ENTREGA ESPERADA
Modelo evaluado + limitaciones

Salida práctica aún pendiente

02 QUÉ REVISAMOS

Perfilado = revisar antes de cambiar

Contamos, comparamos y buscamos anomalías. Todavía no aplicamos limpieza.

1 ¿Cuántas filas y cuántos ID?

```
SELECT COUNT(*) AS FILAS,
 COUNT(DISTINCT INSPECTION_ID) AS ID_DISTINTOS,
 COUNT(*) - COUNT(INSPECTION_ID) AS ID_NULOS
FROM FOOD_INSPECTIONS_RAW;
```

Oracle: 316.961 filas y 316.961 ID distintos; sin ID NULL ni repetidos. DISTINCT cuenta ID diferentes.

3 y 4 ¿Las fechas coinciden?

```
SELECT TO_CHAR(MIN(INSPECTION_DATE),
 'YYYY-MM-DD') AS MINIMA,
 TO_CHAR(MAX(INSPECTION_DATE),
 'YYYY-MM-DD') AS MAXIMA
FROM FOOD_INSPECTIONS_RAW;
```

Oracle y CSV coinciden (consulta 4):
67757 → 2010-01-04 · 2644019 → 2026-10-09
Rango confirmado; sin fechas NULL.

2 ¿Hay contenido?

NULL ≠ [ ]

Oracle: 3 ADDRESS con solo espacios.

5 a 8 ¿Hay variantes?

`Restaurant` → **RESTAURANT**

Ejemplo didáctico. UPPER/TRIM solo comparan; RISK=All se conserva.

9 ¿Se repite contenido?

ID A ≠ ID B
Los campos y la longitud pueden coincidir.

104 grupos candidatos; no confirmados.

12 ¿La licencia falta?

NULL ≠ 0

Oracle: 19 NULL y 837 licencias con valor 0.

03 CÓDIGO QUE HAY QUE DEFENDER

Tres detalles que cambian el diagnóstico

Fragmentos para estudiar. Las consultas completas están en 02profiling.sql.

1 Coordenadas como números

Consulta 10

41,80 ⟶ **41.80**

Ejemplo didáctico: coma decimal → punto.
La conversión se probó en todos los valores no nulos.

```
TO_NUMBER(REPLACE(TRIM(LATITUDE), ',', '.'),
 '999D999999999999999',
 'NLS_NUMERIC_CHARACTERS=''.,''')
```

1.061 faltantes por columna.
0 latitudes y 0 longitudes fuera de rango.

315.900 valores convertidos por columna; sin error.

2 Medir todo el texto

Consulta 11

```
LENGTH(VIOLATIONS)
```

12.706 caracteres máximos (Oracle)

4.469 textos superan 4.000 caracteres.

89.410 NULL · 0 vacíos o solo espacios.

3 Señalar posibles duplicados

Consulta 9

```
HAVING COUNT(DISTINCT INSPECTION_ID) > 1
```

Agrupar campos e igual longitud.
Son candidatos: no se compara el texto del CLOB.

Oracle: 104 grupos candidatos. No implica borrar.

RESULTADOS VERIFICADOS EN ORACLE

04 ENSAYAR Y EXPONER

Contar la historia con evidencia

Reparto sugerido: cada persona guía un bloque; las cuatro deben entender el recorrido completo.

INTEGRANTE 1

Origen y carga

ZIP y coordenadas: texto.

VIOLATIONS: CLOB.
Fechas: DATE.

Mostrar: flujo + tipos.

INTEGRANTE 2

Calidad

NULL, espacios y categorías.

Licencias y valores ambiguos.

Mostrar: resumen + ejemplo.

INTEGRANTE 3

Código clave

ID único y contenido repetido.

CLOB, decimales y rangos.

Mostrar: código + salida.

INTEGRANTE 4

Evidencia y cierre

Qué se comprobó realmente.

Qué reciben Analytics y Science.

Mostrar: estado + pendientes.

Demostración breve en Oracle

1 a 4 → 10 → 11 y 12

Conteos y fechas → coordenadas → textos y licencias.
Capturas sugeridas: 1, 2, 3, 4, 5, 10 y 11.

Tres ideas que no debemos confundir

ID único no descarta contenido repetido.
VIOLATIONS NULL no prueba ausencia de infracciones.
Rango geográfico válido no prueba ubicación en Chicago.

Antes de limpiar

1. Conservar la evidencia de las 12 consultas.
2. Tomar capturas y ensayar los bloques.
3. Decidir el tratamiento de faltantes y categorías.
4. Aprobar las reglas antes de aplicarlas.