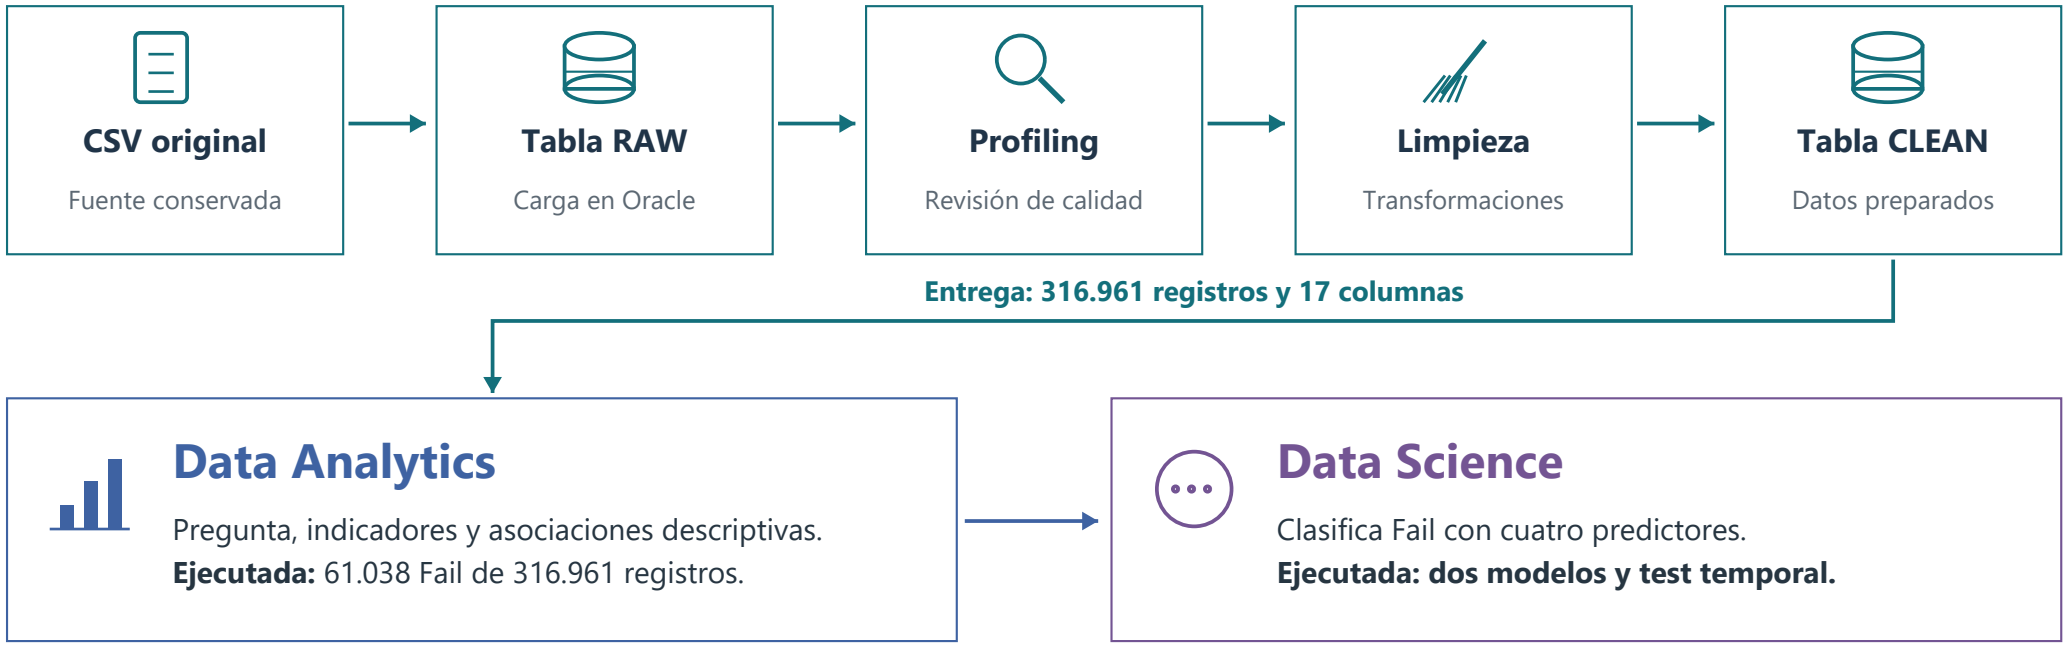
MAPA GENERAL

El caso práctico, paso a paso

Guía de estudio para los cuatro integrantes: identificar la entrada, la operación, la salida y el límite de cada etapa.



Para explicarlo: Engineering prepara; Analytics describe; Science predice Fail y evalúa con datos posteriores.

PALABRAS CLAVE DE ESTA PÁGINA

Dataset

Conjunto de registros sobre un tema.

Proyecto: Chicago Food Inspections es la fuente del caso.

Unidad de análisis

Elemento que representa cada fila.

Proyecto: Una inspección; un local puede tener varias.

Pipeline

Secuencia de pasos que procesa datos.

Proyecto: CSV → RAW → perfilado → limpieza → CLEAN.

DATA ENGINEERING · 1 DE 5

Una inspección genera un registro

El CSV conserva las visitas registradas. No equivale a una lista de establecimientos únicos.



Ilustración didáctica ficticia; no representa un registro real.

ID	Local	Fecha
101	Local A	2026-01-10
102	Local A	2026-04-10
103	Local A	2026-07-10

Ejemplo ficticio: el mismo local aparece en tres fechas. Son tres inspecciones y tres filas.

316.961
registros importados

17
columnas

2010-2026
años representados

Hasta 2026-10-09
Fechas NULL: 0

PALABRAS CLAVE DE ESTA PÁGINA

CSV
Archivo de texto con filas y columnas.
Proyecto: Se importó el archivo original sin editarlo.

INSPECTION_ID
Identificador de una inspección.
Proyecto: 316.961 IDs distintos; no identifica un local.

LICENSE_NUMBER
Número de licencia del establecimiento.
Proyecto: 19 NULL y 837 ceros; puede repetirse entre visitas.

DATA ENGINEERING · 2 DE 5

RAW conserva el punto de partida

Antes de limpiar, se decidió cómo guardar cada columna en Oracle sin perder el contenido original.



CSV → FOOD_INSPECTIONS_RAW

Columna	Tipo en RAW	Decisión
INSPECTION_ID	NUMBER	Identificador numérico.
ZIP	VARCHAR2(20)	Código postal, no cálculo.
INSPECTION_DATE	DATE	Importación: MM/DD/YYYY.
VIOLATIONS	CLOB	Conservar textos extensos.
LATITUDE / LONGITUDE	VARCHAR2(50)	Convertir después de revisar.

12.706

caracteres en el texto más largo de VIOLATIONS.

4.469

textos superan 4.000 caracteres. Esto justifica el uso de CLOB.

89.410 NULL en VIOLATIONS: falta de texto no prueba ausencia de infracciones.

PALABRAS CLAVE DE ESTA PÁGINA

RAW
Datos originales sin limpiar.
Proyecto: FOOD_INSPECTIONS_RAW conserva el CSV.

VARCHAR2
Texto con un tamaño máximo.
Proyecto: Se usó en ZIP y coordenadas originales.

DATE
Tipo de fecha y hora de Oracle.
Proyecto: INSPECTION_DATE se importó como fecha.

CLOB
Tipo para almacenar texto extenso.
Proyecto: Se usa en VIOLATIONS para evitar pérdidas.

DATA ENGINEERING · 3 DE 5

Primero revisamos la calidad

Las 12 consultas de profiling revisaron RAW mediante SELECT. Detectar un problema no autoriza a borrar registros.

Volumen e identificadores

316.961 filas = 316.961 IDs distintos

ID NULL: 0 · Repeticiones de ID: 0

Faltante y espacio no son lo mismo

ADDRESS: 0 NULL, pero 3 textos con solo espacios.
FACILITY_TYPE: 5.357 NULL.
RISK: 87 NULL. En RAW, 12 de 17 columnas tienen NULL.

`COUNT(*) - COUNT(columna)` cuenta NULL.



104 grupos candidatos

Distintos IDs pueden compartir los campos comparados y la misma longitud de VIOLATIONS.

Límite: la consulta no compara todo el texto del CLOB. No confirma duplicados exactos.

Todos estos registros se conservaron.

PALABRAS CLAVE DE ESTA PÁGINA

Profiling
Revisión inicial de calidad.
Proyecto: Se ejecutaron 12 consultas sobre RAW.

NULL
Valor ausente o desconocido.
Proyecto: No equivale a cero ni a un texto útil.

DISTINCT
Selecciona valores diferentes.
Proyecto: COUNT(DISTINCT INSPECTION_ID) cuenta IDs.

Duplicado candidato
Coincidencia todavía por confirmar.
Proyecto: 104 grupos; ninguno fue eliminado.

DATA ENGINEERING · 4 DE 5

Limpiar sin borrar inspecciones

La limpieza crea una tabla nueva. Aplica reglas concretas y copia directamente las otras 12 columnas.

FACILITY_TYPE e INSPECTION_TYPE

`" Banquet Hall "` → `BANQUET HALL`

`UPPER(TRIM(...))`

Ejemplo de escritura; no fusiona categorías por significado.

ADDRESS

`"  "` → `NULL`

`TRIM(ADDRESS)`

Los 3 textos con solo espacios quedaron NULL en Oracle.

LATITUDE y LONGITUDE

`"41,80" (texto)` → `41.80 (NUMBER)`

`TO_NUMBER(...)`

Ejemplo didáctico, no un dato real seleccionado.

Para explicarlo: RESULTS y RISK se conservan. RISK = All no se reinterpretó ni se reclasificó.

PALABRAS CLAVE DE ESTA PÁGINA

TRIM

Quita espacios al inicio y al final.

Proyecto: Limpia ADDRESS y las dos columnas de tipos.

UPPER

Convierte las letras a mayúsculas.

Proyecto: Uniforma FACILITY_TYPE e INSPECTION_TYPE.

TO_NUMBER

Convierte texto a un número.

Proyecto: Se usó con formato decimal explícito en coordenadas.

DATA ENGINEERING · 5 DE 5

CLEAN: mismo volumen, mejores tipos

Las validaciones compararon RAW con CLEAN. Cambiar el formato no implica eliminar filas ni resolver todos los faltantes.

Control	RAW	CLEAN
Registros	316.961	316.961
IDs distintos	316.961	316.961
ADDRESS	0 NULL; 3 con espacios	3 NULL; 0 con espacios
FACILITY_TYPE	527 categorías	473 categorías
INSPECTION_TYPE	110 categorías	98 categorías
Coordenadas	VARCHAR2; 1.061 NULL	NUMBER; 1.061 NULL
VIOLATIONS	CLOB; 89.410 NULL	CLOB; 89.410 NULL

Entrega a Analytics

FOOD_INSPECTIONS_CLEAN
17 columnas y todas las filas.

Columnas usadas en el análisis:
RESULTS
RISK
INSPECTION_TYPE
FACILITY_TYPE
INSPECTION_DATE

Las categorías distintas excluyen NULL. Coordenadas: 0 fuera de los rangos generales; esto no confirma ubicación exacta en Chicago.

PALABRAS CLAVE DE ESTA PÁGINA

CLEAN
Datos después de la limpieza aprobada.

Proyecto: Es la única fuente de las consultas de Analytics.

Normalización
Uniformar la forma de escribir valores.

Proyecto: UPPER/TRIM redujo variantes de los dos tipos.

Validación
Comprobar que el cambio fue correcto.

Proyecto: Latitud: -90 a 90. Longitud: -180 a 180.

DATA ANALYTICS · 1 DE 5

El indicador y su denominador

Pregunta: ¿qué características de las inspecciones están asociadas con una mayor proporción de resultados Fail?

Contamos registros con RESULTS = 'Fail'

61.038
registros con Fail

÷

316.961
todos los registros

× 100 = 19,26 %

El denominador incluye las siete categorías de RESULTS. También cuenta registros No Entry, Not Ready y los demás resultados. No se limita a Pass y Fail.

La operación en SQL

```
COUNT(CASE WHEN RESULTS = 'Fail'
           THEN 1 END) / COUNT(*)
```

El script multiplica por 100 y redondea a dos decimales.

PALABRAS CLAVE DE ESTA PÁGINA

Denominador
Total que se usa para dividir.
Proyecto: 316.961 registros; se mantiene el criterio en grupos.

COUNT
Función SQL que cuenta registros.
Proyecto: COUNT(*) incluye todas las filas del grupo.

Porcentaje
Parte expresada por cada 100.
Proyecto: Fail / total de registros × 100 = 19,26 %.

DATA ANALYTICS · 2 DE 5

Qué significan los siete RESULTS

La columna guarda el resultado registrado. Los nombres no se cambian ni se convierten todos en Pass o Fail.

Resultados del inspector · Diccionario oficial [S2]

Pass — 164.074

Sin infracciones críticas o serias, según el diccionario.

Pass w/ Conditions — 46.991

Las infracciones críticas o serias se corrigieron durante la visita.

Fail — 61.038

Infracciones críticas o serias no corregibles durante la visita.

Out of Business — 25.930

Encontrado fuera de actividad.
Mención general oficial [S2]

Business Not Located — 96

Establecimiento no localizado.
Mención general oficial [S2]

No Entry — 14.206

La etiqueta sugiere que no se ingresó.
Interpretación de etiqueta

Not Ready — 4.626

La etiqueta sugiere que no estaba listo.
Interpretación de etiqueta

Contexto: S1 advierte un cambio de procedimientos en 2018. Estas descripciones de S2 no implican criterios idénticos en todos los años. No Entry y Not Ready no tienen definición clara en las fuentes consultadas.

PALABRAS CLAVE DE ESTA PÁGINA

RESULTS
Columna del resultado registrado.

Proyecto: Tiene siete valores; Fail se cuenta por su texto exacto.

Hallazgo del inspector
Condición observada durante la visita.

Proyecto: S1 confirma que Pass/Conditions/Fail dependen de esos hallazgos.

Interpretación de etiqueta
Lectura sencilla, no definición oficial.

Proyecto: Se usa para No Entry y Not Ready, sin inferir su causa.

DATA ANALYTICS · 3 DE 5

Riesgo declarado y resultado observado

RISK clasifica al establecimiento: 1 es el nivel más alto y 3 el más bajo, según el diccionario oficial [S2].

Tres niveles de riesgo

Risk 3 (Low) — **20,89 %**
Total 24.611 · Fail 5.142

Risk 1 (High) — **19,14 %**
Total 235.944 · Fail 45.157

Risk 2 (Medium) — **19,05 %**
Total 56.232 · Fail 10.712

Escala de las barras: 0 a 30 % de Fail.

All y NULL se conservaron

All — **5,75 %**
Total 87 · Fail 5

NULL (sin dato) — **25,29 %**
Total 87 · Fail 22

87 registros por grupo: son pocos casos; All sigue sin reinterpretarse. No se usa para explicar el efecto del riesgo.

Low tiene 20,89 % y High 19,14 %. Esto no demuestra que el nivel de riesgo cause Fail.

PALABRAS CLAVE DE ESTA PÁGINA

RISK
Clasificación de riesgo del local.
Proyecto: Es una característica, no el resultado de la visita.

Asociación descriptiva
Diferencia observada entre grupos.
Proyecto: Los porcentajes difieren según la categoría registrada.

Causalidad
Que un factor produzca un resultado.
Proyecto: Estas consultas no prueban por qué ocurrió Fail.

DATA ANALYTICS · 4 DE 5

Comparar tipos con suficientes registros

Mínimo de 1.000 registros. Ejemplos seleccionados; barras de 0 a 40 %. Entre paréntesis: lectura en español de las etiquetas.

INSPECTION_TYPE

Tipo o motivo de la visita.

COMPLAINT (queja) 33,23 %
Total 30.075 · Fail 9.993

LICENSE (licencia) 29,75 %
Total 42.512 · Fail 12.646

SUSPECTED FOOD POISONING (posible intoxicación) 25,71 %
Total 1.027 · Fail 264

CANVASS (revisión regular) 18,32 %
Total 163.612 · Fail 29.972

CANVASS RE-INSPECTION (revisita) 8,64 %
Total 35.304 · Fail 3.051

FACILITY_TYPE

Tipo de establecimiento.

LIQUOR (licor) 31,51 %
Total 1.371 · Fail 432

MOBILE FOOD PREPARER (preparación móvil) 25,04 %
Total 1.318 · Fail 330

LONG TERM CARE (cuidado prolongado) 23,22 %
Total 2.438 · Fail 566

GROCERY STORE (supermercado) 22,57 %
Total 37.996 · Fail 8.574

RESTAURANT (restaurante) 18,64 %
Total 215.024 · Fail 40.078

Para explicarlo: COMPLAINT (33,23 %) y LIQUOR (31,51 %) encabezan las salidas con ≥1.000 registros. El volumen y el porcentaje se leen juntos.

PALABRAS CLAVE DE ESTA PÁGINA

INSPECTION_TYPE
Tipo o motivo registrado de la visita.

Proyecto: 9 categorías cumplen el mínimo en la salida SQL.

FACILITY_TYPE
Clasificación del establecimiento.

Proyecto: 12 grupos cumplen el mínimo; SIN DATO no es un tipo real.

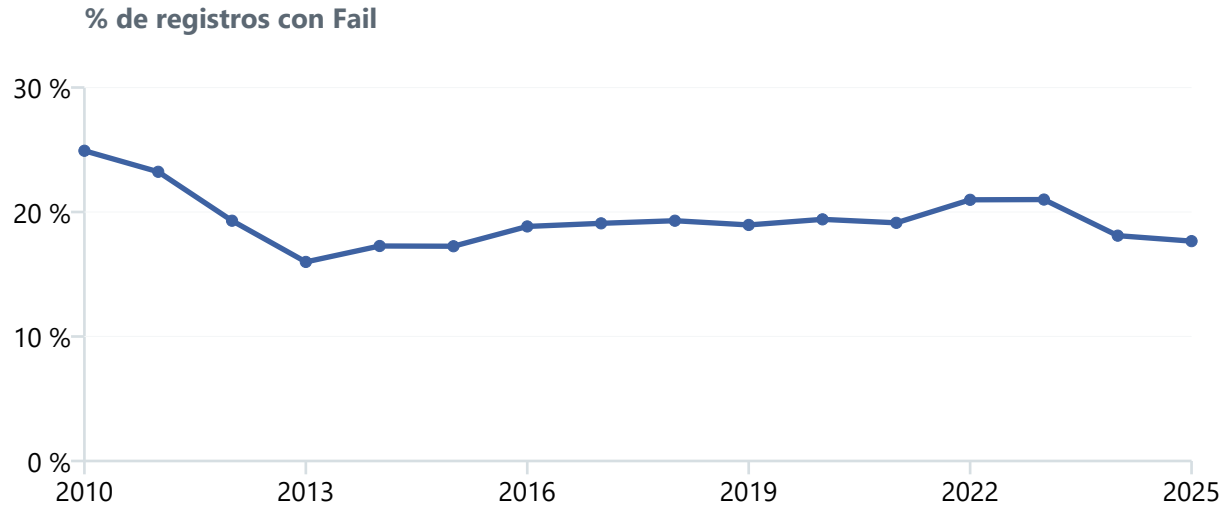
HAVING
Filtra grupos después de contarlos.

Proyecto: HAVING COUNT(*) >= 1000 limita las dos comparaciones.

DATA ANALYTICS · 5 DE 5

Leer el tiempo con sus límites

El porcentaje fluctúa entre años. 2026 tiene datos hasta el 9 de octubre y se presenta por separado.



2010: **24,92 %** · 2013: **15,99 %** · 2025: **17,66 %**. No hay una disminución continua.

2026 · AÑO INCOMPLETO

18,10 %

12.612 registros · 2.283 Fail

No tiene la misma cobertura que un año completo. S1 también advierte cambios de procedimientos desde 2018.

Unidad: un local puede aparecer varias veces. Los porcentajes describen inspecciones; no establecimientos únicos.

NON-INSPECTION: 5.738 registros, 11 Fail. Se conserva, pero no se usa para concluir sobre inspecciones efectivas.

Alcance: sin causalidad. El mínimo omite 3.879 registros por INSPECTION_TYPE y 11.823 por FACILITY_TYPE de las salidas; CLEAN conserva todo.

PALABRAS CLAVE DE ESTA PÁGINA

EXTRACT

Extrae una parte de una fecha.

Proyecto: EXTRACT(YEAR...) agrupa por año de inspección.

Cobertura

Período representado por los registros.

Proyecto: 2026 termina el 9 de octubre en el conjunto usado.

NON-INSPECTION

Etiqueta con significado ambiguo.

Proyecto: Se mantiene en SQL, sin interpretarla como inspección efectiva.

Evidencia: 04analytics.sql, consulta 7 · Límite temporal adicional: portal oficial S1

DATA SCIENCE · 1 DE 5

Predecir Fail con datos previos

Pregunta: ¿podemos anticipar Fail en inspecciones que tienen un resultado sanitario registrado?

Tres RESULTS
Fail · Pass · Pass w/ Conditions

→

Excluir NON-INSPECTION
18 registros del periodo se apartan

→

Años 2019–2025
2026 queda fuera del experimento

FOOD_INSPECTIONS_SCIENCE

Vista de solo lectura sobre CLEAN; conserva la fuente.

103.596
registros utilizados

23.838
Fail: target = 1

79.758
No Fail: target = 0

ENTRAN CUATRO PREDICTORES

RISK | FACILITY_TYPE | ZIP | MES

ANO solo separa train/test. **RESULTS** forma el target; no es predictor. INSPECTION_TYPE solo se usa en el filtro.

SE EXCLUYEN COMO PREDICTORES

VIOLATIONS: hallazgos de la visita, posible fuga de información. Nombres, dirección, licencia y ubicación/coordenadas: posible memorización.

PALABRAS CLAVE DE ESTA PÁGINA

Target
Resultado que queremos predecir.

Proyecto: Fail = 1; Pass/Conditions = 0.

Predictor
Dato usado para anticipar el target.

Proyecto: RISK, FACILITY_TYPE, ZIP y MES.

Clasificación
Asignar una clase a cada registro.

Proyecto: Dos clases: Fail o No Fail.

DATA SCIENCE · 2 DE 5

Aprender del pasado y probar después

Oracle → preparación → modelos → evaluación. El test queda fuera del aprendizaje.

ORACLE
Vista SCIENCE
SELECT, sin copiar una tabla

→

PREPARACIÓN
01_data_prep.py
NULL → SIN DATO; separar años

→

MODELOS
02_models.py
Crear encoder y dos pipelines

→

EVALUACIÓN
03_evaluate.py
Fit con train; predecir test

TRAIN · 2019–2024

87.539 registros

20.447 Fail · 67.092 No Fail

Fail: 23,36 % · categorías aprendidas aquí

TEST · 2025

16.057 registros

3.391 Fail · 12.666 No Fail

Fail: 21,12 % · categorías nuevas permitidas

Baseline: siempre No Fail, la clase mayoritaria de train.
En test acierta **78,88 %**, pero detecta **0 de 3.391 Fail**.

2026 reservado: incompleto hasta el 9 de octubre.
No se entrena ni se evalúa con ese año.

PALABRAS CLAVE DE ESTA PÁGINA

Train
Datos con los que aprende el modelo.
Proyecto: Inspecciones de 2019–2024.

Test
Datos posteriores para evaluar.
Proyecto: Inspecciones de 2025, sin ajuste.

Baseline
Regla sencilla para comparar.
Proyecto: Siempre predice No Fail.

DATA SCIENCE · 3 DE 5

Dos modelos simples y explicables

Mismos predictores y codificación; parámetros fijados antes de evaluar con 2025.

REGRESIÓN LOGÍSTICA

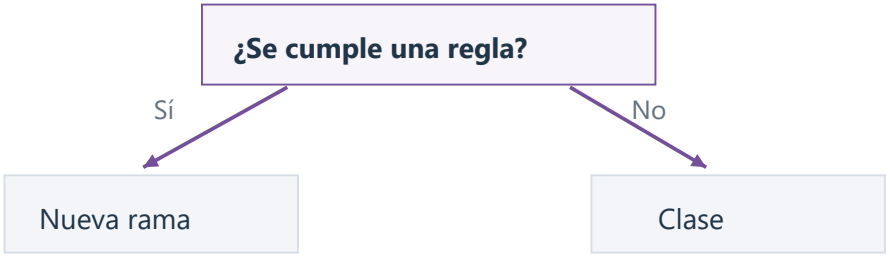
Combina las categorías codificadas para obtener una puntuación y una probabilidad del modelo.



Configuración: C = 1; solver lbfgs; máximo 1.000 iteraciones.
Ejecución: convergió en 70 iteraciones.
Salida: Fail o No Fail; umbral predeterminado 0,5.

ÁRBOL DE DECISIÓN

Aplica preguntas sucesivas sobre las variables y termina en una clase.



Configuración: profundidad máxima 4; mínimo 100 registros por hoja.
Ejecución: 11 hojas. Diagrama conceptual; no son reglas extraídas del árbol.

En ambos: OneHotEncoder permite categorías desconocidas; 340 columnas codificadas. Pesos balanced calculados con train; semilla 42.

PALABRAS CLAVE DE ESTA PÁGINA

Regresión logística
Clasificador que combina predictores.
Proyecto: Modelo principal por recall y F1.

Árbol de decisión
Clasificador basado en reglas y ramas.
Proyecto: Profundidad 4 y 11 hojas.

Accuracy
Proporción de aciertos entre todos.
Proyecto: Baseline: 78,88 %; ningún Fail.

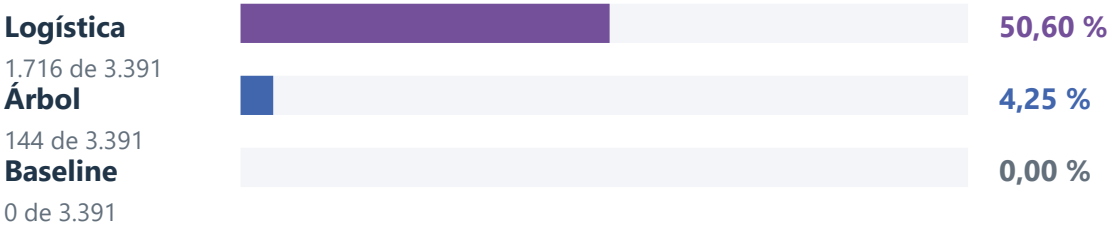
DATA SCIENCE · 4 DE 5

Elegir por detección de Fail

Clase positiva: Fail. Todas las métricas se calculan sobre los mismos 16.057 registros de test.

Modelo	Accuracy	Precision	Recall	F1
Regresión Logística	0,535530	0,228831	0,506045	0,315152
Árbol de Decisión	0,771751	0,256228	0,042465	0,072856
Baseline No Fail	0,788815	0,000000	0,000000	0,000000

RECALL: ¿CUÁNTOS FAIL REALES DETECTAMOS?



Modelo principal: Logística.
Mayor recall y F1 para Fail, aunque su accuracy es menor.

Accuracy sola no basta: el baseline acierta mucho porque No Fail es frecuente; deja escapar todos los Fail.

PALABRAS CLAVE DE ESTA PÁGINA

Precision

De los Fail predichos, cuántos lo son.

Proyecto: Logística: 1.716/7.499 = 22,88 %.

Recall

De los Fail reales, cuántos detecta.

Proyecto: Logística: 1.716/3.391 = 50,60 %.

F1

Combina precision y recall en un valor.

Proyecto: Logística: 0,315152; árbol: 0,072856.

DATA SCIENCE · 5 DE 5

Leer los errores y reconocer los límites

Matrices: filas = resultado real; columnas = predicción. Orden de clases: No Fail (0), Fail (1).

REGRESIÓN LOGÍSTICA

	Pred. No Fail	Pred. Fail
No Fail	6.883	5.783
Fail	1.675	1.716

3.391 Fail reales en cada matriz

ÁRBOL DE DECISIÓN

	Pred. No Fail	Pred. Fail
No Fail	12.248	418
Fail	3.247	144

3.391 Fail reales en cada matriz

BASELINE NO FAIL

	Pred. No Fail	Pred. Fail
No Fail	12.666	0
Fail	3.391	0

3.391 Fail reales en cada matriz

LOS RESULTADOS NO JUSTIFICAN USO OPERATIVO

Errores y alcance: Logística genera 5.783 falsos positivos y pierde 1.675 Fail. Un local puede repetirse en train y test; no se prueba solo con locales nuevos.

Datos y supuestos: categorías raras/nuevas y atributos previos asumidos. La vista cambia si CLEAN cambia. Predicción no demuestra causalidad; 2026 no participa.

PALABRAS CLAVE DE ESTA PÁGINA

Matriz de confusión

Cruza resultados reales y predichos.

Proyecto: Cada matriz suma 16.057 casos.

Falso positivo

No Fail real señalado como Fail.

Proyecto: Logística: 5.783 falsas alarmas.

Falso negativo

Fail real señalado como No Fail.

Proyecto: Logística: 1.675 Fail no detectados.