01 Mapa del caso práctico

Guía visual para la exposición del caso práctico

Bases de Datos II · Apoyo interno para cuatro integrantes · Estado al 11 de octubre de 2026

La carga RAW y un perfilado inicial están documentados. El script ampliado está preparado; falta ejecutarlo en Oracle y guardar sus resultados. La limpieza, Data Analytics y Data Science siguen pendientes.

Dataset	Unidad de análisis	Campos principales
Chicago Food Inspections	Una fila representa una inspección; un establecimiento puede aparecer muchas veces.	ID, fecha, licencia, establecimiento, riesgo, resultado, infracciones y ubicación.

Del archivo original al análisis

1. **CSV original** — CONSERVADO
   316.961 inspecciones y 17 columnas
2. **FOOD_INSPECTIONS_RAW** — CARGA DOCUMENTADA
   Carga en Oracle y tipos definidos
3. **Perfilado** — VALIDACIÓN PENDIENTE
   Diagnóstico P01 a P34 sin modificar filas
4. **Limpieza y transformación** — PENDIENTE
   Reglas por aprobar y aplicar
5. **Datos preparados** — PENDIENTE
   Salida validada para los análisis
6. **Data Analytics** — PENDIENTE
   Consultas e indicadores para responder preguntas
7. **Data Science** — PENDIENTE
   Problema, variables, modelo y evaluación

La flecha indica la dependencia entre etapas. Data Science recibirá datos preparados y podrá usar hallazgos de Data Analytics; todavía no hay resultados ni modelo práctico.

Decisiones vigentes de carga

VIOLATIONS → CLOB para conservar textos extensos. **ZIP → texto** porque es un código. **Coordenadas → texto en RAW** para conservar la representación recibida. **Fecha → DATE** con importación declarada MM/DD/YYYY, pendiente de contraste.

La guía se actualizará al cerrar cada etapa. Las decisiones reemplazadas se retirarán y cada resultado indicará si procede del CSV, del perfilado inicial o de una ejecución de Oracle.

02 Conteos fechas y valores ausentes

P02 Qué cantidad se cargó y qué tan único es el ID

```
SELECT COUNT(*) AS TOTAL_REGISTROS,
       COUNT(DISTINCT INSPECTION_ID) AS ID_DISTINTOS,
       COUNT(*) - COUNT(INSPECTION_ID) AS ID_NULOS
FROM FOOD_INSPECTIONS_RAW;
```

Fragmento reducido de P02. COUNT(*) cuenta filas; COUNT(DISTINCT) cuenta ID diferentes y omite NULL. El conteo inicial documentado es 316.961. Hay que repetirlo y guardar ambas cantidades.

P03 y P04 Cómo demostrar la fecha almacenada

```
SELECT TO_CHAR(MIN(INSPECTION_DATE), 'YYYY-MM-DD')
           AS FECHA_MINIMA,
       TO_CHAR(MAX(INSPECTION_DATE), 'YYYY-MM-DD')
           AS FECHA_MAXIMA
FROM FOOD_INSPECTIONS_RAW;
```

Fragmento reducido de P03. Mostrar YYYY-MM-DD elimina la ambigüedad al leer día y mes. Oracle DATE almacena la fecha; su presentación en pantalla depende del formato utilizado.

ID de contraste	Texto en CSV	Fecha esperada desde CSV
67757	01/04/2010	2010-01-04
2644019	10/09/2026	2026-10-09

P04 compara estas fechas con Oracle y muestra COINCIDE, FECHA NULA, ID AUSENTE o REVISAR DIFERENCIA. Las fechas anteriores del informe se dejaron sin confirmar; no se afirmó un error de importación.

P06 y P07 NULL no equivale a un texto de espacios

```
SELECT INSPECTION_ID, '[' || ADDRESS || ']' AS VALOR
FROM FOOD_INSPECTIONS_RAW
WHERE ADDRESS IS NOT NULL
  AND REGEXP_LIKE(ADDRESS, '^[[:space:]]*$', 'c');
```

Ejemplo reducido del diagnóstico de P07. Los corchetes hacen visible un texto sin contenido útil. P06 realiza el conteo completo para las 17 columnas y también contempla CLOB vacíos.

Para defenderlo: cero NULL en ADDRESS no demuestra que todas las direcciones tengan contenido. Tampoco basta que coincida el número de filas para demostrar que fechas y textos se importaron correctamente.

03 Categorías duplicados y licencias

P15 a P24 Qué significan las variantes de escritura

```
SELECT FACILITY_TYPE, COUNT(*) AS CANTIDAD
FROM FOOD_INSPECTIONS_RAW
GROUP BY FACILITY_TYPE
ORDER BY CANTIDAD DESC, FACILITY_TYPE;
```

P16 muestra la frecuencia de cada valor original. P17 agrega INSPECTION_TYPE. P18 a P20 cubren CITY, STATE y ZIP. P21 y P22 contrastan valores originales con UPPER(TRIM(...)) y muestran variantes. P12 a P14 revisan RISK; All se conserva sin reclasificar hasta confirmar su significado.

Operación	Qué permite observar	Qué no decide
GROUP BY + COUNT(*)	Frecuencia de cada valor original.	Si una categoría es correcta.
UPPER(TRIM(valor))	Posibles diferencias por letras y espacios externos.	Qué categorías deben unificarse.
Formato de ZIP	Texto vacío, 5 dígitos, ZIP+4 u otro formato.	Pertenencia a Chicago ni validez postal real.

P08 a P10 ID único no descarta contenido repetido

P08 busca repeticiones del ID. **P09** agrupa candidatos por las otras columnas y la longitud del texto, compara el CLOB completo y resume grupos y filas adicionales. **P10** muestra pares con ID distintos.

```
DBMS_LOB.COMPARE(a.VIOLATIONS, b.VIOLATIONS) = 0
```

Condición clave de P09 y P10, no una consulta independiente. El script trata por separado los dos CLOB NULL y compara las demás columnas con igualdad que contempla NULL. No basta comparar los primeros 4.000 caracteres.

P33 y P34 Licencias que requieren investigación

```
SELECT COUNT(CASE WHEN LICENSE_NUMBER IS NULL
                  THEN 1 END) AS LICENCIAS_NULAS,
       COUNT(CASE WHEN LICENSE_NUMBER = 0
                  THEN 1 END) AS LICENCIAS_CERO
FROM FOOD_INSPECTIONS_RAW;
```

Fragmento reducido de P33. NULL y 0 se cuentan por separado. P34 muestra ejemplos antes de usar la licencia para identificar establecimientos. No se ha aprobado reemplazar ni eliminar estos casos.

Para defenderlo: repetir una licencia puede ser normal porque existen varias inspecciones de un establecimiento. Un duplicado de contenido exige investigar su significado antes de borrar una fila.

04 Coordenadas y coherencia geográfica

En el CSV revisado las coordenadas usan coma decimal; LOCATION usa punto decimal y una coma entre componentes. El perfilado debe distinguir esas dos funciones de la coma.

P25 y P26 Conversión explícita y segura

```
CASE WHEN REGEXP_LIKE(LAT_TEXTO,
             '^[+-]?[0-9]+([.,][0-9]+)?$', 'c')
     THEN TO_NUMBER(
          REPLACE(LAT_TEXTO, ',', '.')
          DEFAULT NULL ON CONVERSION ERROR,
          '9999999999999999999D999999999999999999',
          'NLS_NUMERIC_CHARACTERS=''.,''')
END AS LAT_NUM
```

Fragmento de la expresión utilizada en el script. LAT_TEXTO se obtiene del texto original. La expresión regular acepta un número con signo opcional y un separador decimal; REPLACE presenta ese separador como punto. La máscara y NLS fijan cómo Oracle interpreta el número.

Paso	Comprobación
1 · Disponibilidad	Distinguir NULL y espacios de un número con formato incorrecto.
2 · Conversión	Convertir con formato explícito; un fallo queda identificado como NULL de conversión.
3 · Rango	Latitud entre -90 y 90; longitud entre -180 y 180.
4 · Comparación	P27 compara coordenadas con LOCATION cuando los tres textos están disponibles. P28 muestra casos a revisar.

P27 Por qué se usa una tolerancia

```
ABS(LAT_NUM - LOC_LAT_NUM) <= 0.00000001
AND ABS(LON_NUM - LOC_LON_NUM) <= 0.00000001
```

Condición de coherencia, no consulta independiente. Permite diferencias diminutas de representación. P27 separa formatos no comparables de diferencias numéricas; también cuenta los formatos inválidos de LOCATION.

Para defenderlo: una coordenada puede estar dentro del rango mundial y quedar fuera de Chicago. La coincidencia con LOCATION tampoco demuestra que la dirección postal sea correcta.

Pendiente: ejecutar P25 a P28 y confirmar en Oracle el conteo de ausentes, conversiones inválidas, rangos y discrepancias. Las funciones de conversión utilizadas requieren Oracle 12.2 o posterior.

05 Textos extensos resultados y evidencia

P29 y P30 Cómo medir y contrastar el texto completo

```
SELECT MAX(DBMS_LOB.GETLENGTH(VIOLATIONS))
           AS LONGITUD_MAXIMA,
       COUNT(CASE WHEN DBMS_LOB.GETLENGTH(VIOLATIONS)
                       > 4000 THEN 1 END)
           AS TEXTOS_MAYORES_4000
FROM FOOD_INSPECTIONS_RAW;
```

Fragmento reducido de P29. GETLENGTH mide todo el CLOB en caracteres. P30 muestra los 20 casos más largos, su ID y vistas del inicio y final. P31 muestra intervalos; P32 relaciona la ausencia de texto con RESULTS.

Valores de contraste que todavía requieren Oracle

Hallazgo en el CSV revisado	Referencia	Validación
Rango de fechas	2010-01-04 a 2026-10-09	P03 y P04
Direcciones solo de espacios	3 filas	P06 y P07
Contenido idéntico sin comparar ID	102 grupos; 214 filas; 112 adicionales	P09 y P10
Longitud máxima de VIOLATIONS	12.706 caracteres; ID 2617205	P29 y P30
VIOLATIONS mayores de 4.000	4.469 filas	P29
Licencias vacías y cero	19 vacías; 837 con valor 0	P33 y P34

Estos valores proceden de la revisión del archivo CSV. No se presentan como salidas del script ejecutado en Oracle. Los NULL y frecuencias del perfilado inicial conservados en el informe también deben revalidarse.

Qué guardar después de ejecutar

Primero: P01 a P04, P25 a P28 y P29 a P30. Después ejecutar las demás consultas completas. P09 y P10 comparan contenido y pueden tardar más; cada bloque WITH debe ejecutarse junto con su SELECT final.

Evidencia: código de consulta, fecha de ejecución, salida completa de los conteos y muestras con ID. Priorizar fechas, NULL y espacios, grupos duplicados, variantes, conversiones y coherencia, textos largos y licencias. Una salida sin filas también debe registrarse.

Limitación: las muestras tienen límites de 20, 50 o 100 filas. Sirven para explicar ejemplos; los totales deben obtenerse de las consultas de resumen. Un VIOLATIONS NULL no prueba que no existieron infracciones.

06 Preparación de los cuatro integrantes

Qué recibe y qué entrega cada disciplina

Disciplina	Recibe	Entrega esperada y estado
Data Engineering	CSV original y contexto del dataset.	Datos preparados y evidencia de calidad. Carga y perfilado inicial documentados; cierre del perfilado y limpieza pendientes.
Data Analytics	Datos preparados por Engineering.	Indicadores, visualizaciones e interpretación. Etapa práctica pendiente.
Data Science	Datos preparados y preguntas; puede utilizar hallazgos de Analytics.	Modelo o técnica estadística, evaluación y limitaciones. Problema, variables y modelo pendientes.

Reparto sugerido para ensayar

Integrante	Bloque principal
1	Dataset, carga RAW y tipos de datos; conteos y fechas.
2	NULL, espacios, categorías, RISK y licencias.
3	Duplicados, comparación del CLOB y coordenadas con NLS explícito.
4	Evidencia, límites del perfilado y conexión con las etapas pendientes.

El reparto organiza la exposición. Los cuatro deben poder explicar P02, P04, P06, P09/P10, P25/P27, P29 y P33; no basta memorizar su propio bloque.

Flujo breve para exponer

1. Presentar una inspección como unidad de análisis y el CSV conservado.
2. Mostrar RAW y justificar DATE, CLOB y columnas de texto.
3. Ejecutar conteos y contraste de fechas.
4. Mostrar un resumen y un ejemplo de calidad: espacios, categorías o duplicados.
5. Demostrar conversión de coordenadas y longitud del CLOB.
6. Explicar qué queda pendiente y qué recibirá cada disciplina.

Respuestas que todos deben poder defender

¿Por qué solo SELECT? Para diagnosticar antes de aprobar cambios.
¿Por qué conservar RAW? Para contrastar resultados con la fuente.
¿Por qué no borrar duplicados ahora? Porque coincidencia de contenido no basta para decidir su tratamiento.
¿Cuándo termina el perfilado? Al ejecutar los controles, guardar evidencia y resolver las discrepancias del informe.

Siguiente cierre: confirmar las salidas en Oracle, actualizar el apartado práctico y esta guía, y después someter las reglas de limpieza a aprobación. No hay todavía indicadores finales ni resultados de Data Science.