01 EL MAPA

Del CSV a las respuestas

Una fila representa una inspección. Un establecimiento puede tener muchas inspecciones.

316.961
registros

17
columnas

1 fila
una inspección

Carga RAW y perfilado inicial documentados.
Falta ejecutar P01 a P34 en Oracle.

1 **CSV**
original
CONSERVADO

→

2 **Tabla RAW**
en Oracle
CARGADA

→

3 **Perfilado**
revisar calidad
POR VALIDAR

→

4 **Limpieza**
transformar
PENDIENTE

→

5 **Datos**
preparados
PENDIENTE

→

6 **Analytics**
analizar
PENDIENTE

→

7 **Science**
modelar
PENDIENTE

RAW = FOOD_INSPECTIONS_RAW · El CSV se conserva · El perfilado usa solo SELECT

Engineering

RECIBE
CSV original

ENTREGA ESPERADA
Datos preparados + evidencia

Salida práctica aún pendiente

Analytics

RECIBE
Datos preparados

ENTREGA ESPERADA
Indicadores + interpretación

Salida práctica aún pendiente

Science

RECIBE
Datos preparados + pregunta

ENTREGA ESPERADA
Modelo evaluado + limitaciones

Salida práctica aún pendiente

ORACLE: VALIDACIÓN AMPLIADA PENDIENTE

02 QUÉ REVISAMOS

Perfilado = revisar antes de cambiar

Contamos, comparamos y buscamos anomalías. Todavía no aplicamos limpieza.

P02 ¿Cuántas filas y cuántos ID?

```
SELECT COUNT(*) AS FILAS,
 COUNT(DISTINCT INSPECTION_ID) AS ID_DISTINTOS,
 COUNT(*) - COUNT(INSPECTION_ID) AS ID_NULOS
FROM FOOD_INSPECTIONS_RAW;
```

COUNT(*) cuenta filas. DISTINCT cuenta ID distintos y omite NULL. Revalidar las 316.961 filas documentadas.

P03 y P04 ¿Las fechas coinciden?

```
SELECT TO_CHAR(MIN(INSPECTION_DATE),
 'YYYY-MM-DD') AS MINIMA,
 TO_CHAR(MAX(INSPECTION_DATE),
 'YYYY-MM-DD') AS MAXIMA
FROM FOOD_INSPECTIONS_RAW;
```

CSV esperado en P04:
67757 → 2010-01-04 · 2644019 → 2026-10-09
Confirmar estas fechas en Oracle.

P06 y P07 ¿Hay contenido?

NULL ≠ [ ]

Sin valor y solo espacios son casos distintos.

P15 a P24 ¿Hay variantes?

`Restaurant` → **RESTAURANT**

Ejemplo didáctico. UPPER/TRIM solo comparan; RISK=All se conserva.

P08 a P10 ¿Se repite contenido?

ID A ≠ ID B
Las otras 16 columnas pueden ser iguales.

ID único no descarta contenido duplicado.

P33 y P34 ¿La licencia falta?

NULL ≠ 0

Se cuentan por separado; no se reemplazan.

03 CÓDIGO QUE HAY QUE DEFENDER

Tres detalles que cambian el diagnóstico

Fragmentos para estudiar. Las consultas completas están en 02profiling.sql.

1 Coordenadas como números

P25 a P28

41,80 → 41.80

Ejemplo didáctico: coma decimal → punto.
El script valida el formato antes de convertir.

```
TO_NUMBER(REPLACE(LAT_TEXTO, ',', '.')
 DEFAULT NULL ON CONVERSION ERROR,
 '9999999999999999999D99999999999999999',
 'NLS_NUMERIC_CHARACTERS=''.,''')
```

Validar número → rango → LOCATION.
Comparación con tolerancia de 0,00000001 grados.

Formato y NLS explícitos. Requiere Oracle 12.2+.

2 Medir todo el texto

P29 y P30

```
DBMS_LOB.GETLENGTH(VIOLATIONS)
```

Expresión de diagnóstico, no consulta completa.

12.706 caracteres máximos (CSV)

4.469 textos superan 4.000 caracteres.

3 Comparar contenido completo

P09 y P10

```
DBMS_LOB.COMPARE(a.VIOLATIONS, b.VIOLATIONS) = 0
```

En el CSV: 102 grupos; 112 filas adicionales. No implica borrar.

Comparar las 16 columnas sin ID.
El CLOB se compara entero; NULL se contempla por separado.

CIFRAS DEL CSV · POR CONFIRMAR EN ORACLE

ORACLE: VALIDACIÓN AMPLIADA PENDIENTE

04 ENSAYAR Y EXPONER

Contar la historia con evidencia

Reparto sugerido: cada persona guía un bloque; las cuatro deben entender el recorrido completo.

INTEGRANTE 1

Origen y carga

ZIP y coordenadas: texto.

VIOLATIONS: CLOB.
Fechas: DATE.

Mostrar: flujo + tipos.

INTEGRANTE 2

Calidad

NULL, espacios y categorías.

Licencias y valores ambiguos.

Mostrar: resumen + ejemplo.

INTEGRANTE 3

Código clave

ID único y contenido repetido.

CLOB, decimales y LOCATION.

Mostrar: código + salida.

INTEGRANTE 4

Evidencia y cierre

Qué se comprobó realmente.

Qué reciben Analytics y Science.

Mostrar: estado + pendientes.

Demostración inicial en Oracle

P01-P04 → P25-P28 → P29-P30

Conteos y fechas → coordenadas → textos largos.
Después: ejecutar las consultas restantes.

Tres ideas que no debemos confundir

ID único no descarta contenido repetido.
VIOLATIONS NULL no prueba ausencia de infracciones.
Rango geográfico válido no prueba ubicación en Chicago.

Antes de limpiar

1. Ejecutar los 34 diagnósticos.
2. Guardar consulta, fecha, salida e ID de ejemplo.
3. Contrastar con el CSV y resolver diferencias.
4. Aprobar las reglas de limpieza.

ORACLE: VALIDACIÓN AMPLIADA PENDIENTE