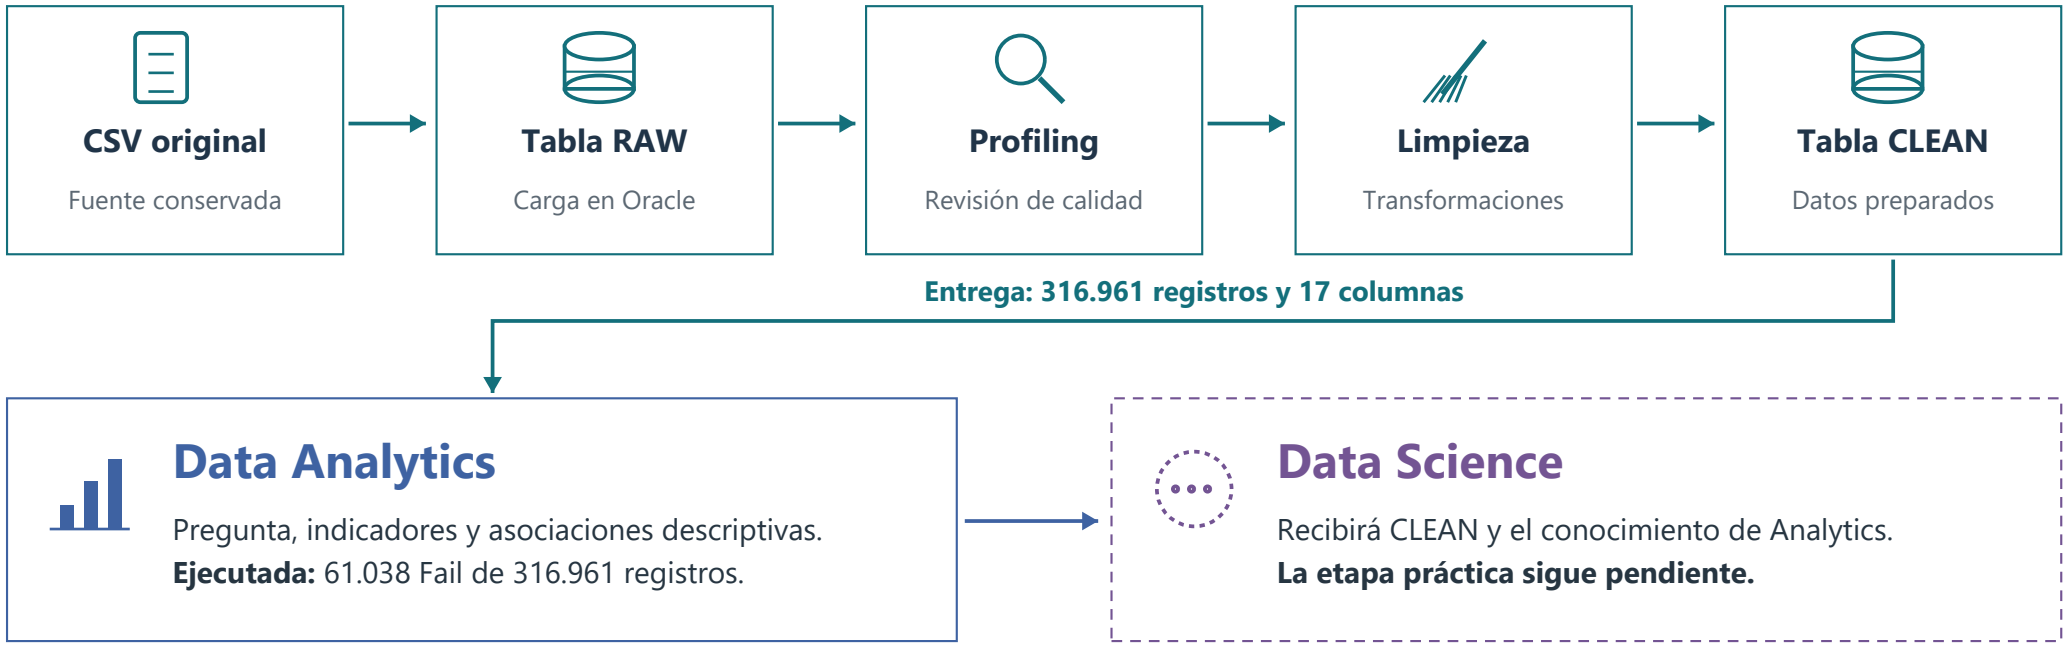
MAPA GENERAL

El caso práctico, paso a paso

Guía de estudio para los cuatro integrantes: identificar la entrada, la operación, la salida y el límite de cada etapa.



Para explicarlo: Engineering prepara; Analytics describe; Science todavía no ha desarrollado su análisis práctico.

PALABRAS CLAVE DE ESTA PÁGINA

Dataset
Conjunto de registros sobre un tema.

Proyecto: Chicago Food Inspections es la fuente del caso.

Unidad de análisis
Elemento que representa cada fila.

Proyecto: Una inspección; un local puede tener varias.

Pipeline
Secuencia de pasos que procesa datos.

Proyecto: CSV → RAW → perfilado → limpieza → CLEAN.

DATA ENGINEERING · 1 DE 5

Una inspección genera un registro

El CSV conserva las visitas registradas. No equivale a una lista de establecimientos únicos.



Ilustración didáctica ficticia; no representa un registro real.

ID	Local	Fecha
101	Local A	2026-01-10
102	Local A	2026-04-10
103	Local A	2026-07-10

Ejemplo ficticio: el mismo local aparece en tres fechas. Son tres inspecciones y tres filas.

316.961
registros importados

17
columnas

2010-2026
años representados

Hasta 2026-10-09
Fechas NULL: 0

PALABRAS CLAVE DE ESTA PÁGINA

CSV
Archivo de texto con filas y columnas.
Proyecto: Se importó el archivo original sin editarlo.

INSPECTION_ID
Identificador de una inspección.
Proyecto: 316.961 IDs distintos; no identifica un local.

LICENSE_NUMBER
Número de licencia del establecimiento.
Proyecto: 19 NULL y 837 ceros; puede repetirse entre visitas.

DATA ENGINEERING · 2 DE 5

RAW conserva el punto de partida

Antes de limpiar, se decidió cómo guardar cada columna en Oracle sin perder el contenido original.



CSV → FOOD_INSPECTIONS_RAW

Columna	Tipo en RAW	Decisión
INSPECTION_ID	NUMBER	Identificador numérico.
ZIP	VARCHAR2(20)	Código postal, no cálculo.
INSPECTION_DATE	DATE	Importación: MM/DD/YYYY.
VIOLATIONS	CLOB	Conservar textos extensos.
LATITUDE / LONGITUDE	VARCHAR2(50)	Convertir después de revisar.

12.706

caracteres en el texto más largo de VIOLATIONS.

4.469

textos superan 4.000 caracteres. Esto justifica el uso de CLOB.

89.410 NULL en VIOLATIONS: falta de texto no prueba ausencia de infracciones.

PALABRAS CLAVE DE ESTA PÁGINA

RAW
Datos originales sin limpiar.
Proyecto: FOOD_INSPECTIONS_RAW conserva el CSV.

VARCHAR2
Texto con un tamaño máximo.
Proyecto: Se usó en ZIP y coordenadas originales.

DATE
Tipo de fecha y hora de Oracle.
Proyecto: INSPECTION_DATE se importó como fecha.

CLOB
Tipo para almacenar texto extenso.
Proyecto: Se usa en VIOLATIONS para evitar pérdidas.

Evidencia: 01create_raw.sql, 02profiling.sql y limpieza_resumen.txt

DATA ENGINEERING · 3 DE 5

Primero revisamos la calidad

Las 12 consultas de profiling revisaron RAW mediante SELECT. Detectar un problema no autoriza a borrar registros.

Volumen e identificadores

316.961 filas = 316.961 IDs distintos

ID NULL: 0 · Repeticiones de ID: 0

Faltante y espacio no son lo mismo

ADDRESS: 0 NULL, pero 3 textos con solo espacios.
FACILITY_TYPE: 5.357 NULL.
RISK: 87 NULL. En RAW, 12 de 17 columnas tienen NULL.

`COUNT(*) - COUNT(columna)` cuenta NULL.



104 grupos candidatos

Distintos IDs pueden compartir los campos comparados y la misma longitud de VIOLATIONS.

Límite: la consulta no compara todo el texto del CLOB. No confirma duplicados exactos.

Todos estos registros se conservaron.

PALABRAS CLAVE DE ESTA PÁGINA

Profiling
Revisión inicial de calidad.
Proyecto: Se ejecutaron 12 consultas sobre RAW.

NULL
Valor ausente o desconocido.
Proyecto: No equivale a cero ni a un texto útil.

DISTINCT
Selecciona valores diferentes.
Proyecto: COUNT(DISTINCT INSPECTION_ID) cuenta IDs.

Duplicado candidato
Coincidencia todavía por confirmar.
Proyecto: 104 grupos; ninguno fue eliminado.

DATA ENGINEERING · 4 DE 5

Limpiar sin borrar inspecciones

La limpieza crea una tabla nueva. Aplica reglas concretas y copia directamente las otras 12 columnas.

FACILITY_TYPE e INSPECTION_TYPE

`" Banquet Hall "` → `BANQUET HALL`

`UPPER(TRIM(...))`

Ejemplo de escritura; no fusiona categorías por significado.

ADDRESS

`"  "` → `NULL`

`TRIM(ADDRESS)`

Los 3 textos con solo espacios quedaron NULL en Oracle.

LATITUDE y LONGITUDE

`"41,80" (texto)` → `41.80 (NUMBER)`

`TO_NUMBER(...)`

Ejemplo didáctico, no un dato real seleccionado.

Para explicarlo: RESULTS y RISK se conservan. RISK = All no se reinterpretó ni se reclasificó.

PALABRAS CLAVE DE ESTA PÁGINA

TRIM

Quita espacios al inicio y al final.

Proyecto: Limpia ADDRESS y las dos columnas de tipos.

UPPER

Convierte las letras a mayúsculas.

Proyecto: Uniforma FACILITY_TYPE e INSPECTION_TYPE.

TO_NUMBER

Convierte texto a un número.

Proyecto: Se usó con formato decimal explícito en coordenadas.

DATA ENGINEERING · 5 DE 5

CLEAN: mismo volumen, mejores tipos

Las validaciones compararon RAW con CLEAN. Cambiar el formato no implica eliminar filas ni resolver todos los faltantes.

Control	RAW	CLEAN
Registros	316.961	316.961
IDs distintos	316.961	316.961
ADDRESS	0 NULL; 3 con espacios	3 NULL; 0 con espacios
FACILITY_TYPE	527 categorías	473 categorías
INSPECTION_TYPE	110 categorías	98 categorías
Coordenadas	VARCHAR2; 1.061 NULL	NUMBER; 1.061 NULL
VIOLATIONS	CLOB; 89.410 NULL	CLOB; 89.410 NULL

Entrega a Analytics

FOOD_INSPECTIONS_CLEAN
17 columnas y todas las filas.

Columnas usadas en el análisis:
RESULTS
RISK
INSPECTION_TYPE
FACILITY_TYPE
INSPECTION_DATE

Las categorías distintas excluyen NULL. Coordenadas: 0 fuera de los rangos generales; esto no confirma ubicación exacta en Chicago.

PALABRAS CLAVE DE ESTA PÁGINA

CLEAN
Datos después de la limpieza aprobada.

Proyecto: Es la única fuente de las consultas de Analytics.

Normalización
Uniformar la forma de escribir valores.

Proyecto: UPPER/TRIM redujo variantes de los dos tipos.

Validación
Comprobar que el cambio fue correcto.

Proyecto: Latitud: -90 a 90. Longitud: -180 a 180.

DATA ANALYTICS · 1 DE 5

El indicador y su denominador

Pregunta: ¿qué características de las inspecciones están asociadas con una mayor proporción de resultados Fail?

Contamos registros con RESULTS = 'Fail'

61.038
registros con Fail

÷

316.961
todos los registros

× 100 = 19,26 %

El denominador incluye las siete categorías de RESULTS. También cuenta registros No Entry, Not Ready y los demás resultados. No se limita a Pass y Fail.

La operación en SQL

```
COUNT(CASE WHEN RESULTS = 'Fail'
           THEN 1 END) / COUNT(*)
```

El script multiplica por 100 y redondea a dos decimales.

PALABRAS CLAVE DE ESTA PÁGINA

Denominador
Total que se usa para dividir.
Proyecto: 316.961 registros; se mantiene el criterio en grupos.

COUNT
Función SQL que cuenta registros.
Proyecto: COUNT(*) incluye todas las filas del grupo.

Porcentaje
Parte expresada por cada 100.
Proyecto: Fail / total de registros × 100 = 19,26 %.

DATA ANALYTICS · 2 DE 5

Qué significan los siete RESULTS

La columna guarda el resultado registrado. Los nombres no se cambian ni se convierten todos en Pass o Fail.

Resultados del inspector · Diccionario oficial [S2]

Pass — 164.074

Sin infracciones críticas o serias, según el diccionario.

Pass w/ Conditions — 46.991

Las infracciones críticas o serias se corrigieron durante la visita.

Fail — 61.038

Infracciones críticas o serias no corregibles durante la visita.

Out of Business — 25.930

Encontrado fuera de actividad.

Mención general oficial [S2]

Business Not Located — 96

Establecimiento no localizado.

Mención general oficial [S2]

No Entry — 14.206

La etiqueta sugiere que no se ingresó.

Interpretación de etiqueta

Not Ready — 4.626

La etiqueta sugiere que no estaba listo.

Interpretación de etiqueta

Contexto: S1 advierte un cambio de procedimientos en 2018. Estas descripciones de S2 no implican criterios idénticos en todos los años. No Entry y Not Ready no tienen definición clara en las fuentes consultadas.

PALABRAS CLAVE DE ESTA PÁGINA

RESULTS
Columna del resultado registrado.

Proyecto: Tiene siete valores; Fail se cuenta por su texto exacto.

Hallazgo del inspector
Condición observada durante la visita.

Proyecto: S1 confirma que Pass/Conditions/Fail dependen de esos hallazgos.

Interpretación de etiqueta
Lectura sencilla, no definición oficial.

Proyecto: Se usa para No Entry y Not Ready, sin inferir su causa.

DATA ANALYTICS · 3 DE 5

Riesgo declarado y resultado observado

RISK clasifica al establecimiento: 1 es el nivel más alto y 3 el más bajo, según el diccionario oficial [S2].

Tres niveles de riesgo

Risk 3 (Low) 20,89 %
Total 24.611 · Fail 5.142

Risk 1 (High) 19,14 %
Total 235.944 · Fail 45.157

Risk 2 (Medium) 19,05 %
Total 56.232 · Fail 10.712

Escala de las barras: 0 a 30 % de Fail.

All y NULL se conservaron

All 5,75 %
Total 87 · Fail 5

NULL (sin dato) 25,29 %
Total 87 · Fail 22

87 registros por grupo: son pocos casos; All sigue sin reinterpretarse. No se usa para explicar el efecto del riesgo.

Low tiene 20,89 % y High 19,14 %. Esto no demuestra que el nivel de riesgo cause Fail.

PALABRAS CLAVE DE ESTA PÁGINA

RISK
Clasificación de riesgo del local.
Proyecto: Es una característica, no el resultado de la visita.

Asociación descriptiva
Diferencia observada entre grupos.
Proyecto: Los porcentajes difieren según la categoría registrada.

Causalidad
Que un factor produzca un resultado.
Proyecto: Estas consultas no prueban por qué ocurrió Fail.

DATA ANALYTICS · 4 DE 5

Comparar tipos con suficientes registros

Mínimo de 1.000 registros. Ejemplos seleccionados; barras de 0 a 40 %. Entre paréntesis: lectura en español de las etiquetas.

INSPECTION_TYPE

Tipo o motivo de la visita.

COMPLAINT (queja) 33,23 %
Total 30.075 · Fail 9.993

LICENSE (licencia) 29,75 %
Total 42.512 · Fail 12.646

SUSPECTED FOOD POISONING (posible intoxicación) 25,71 %
Total 1.027 · Fail 264

CANVASS (revisión regular) 18,32 %
Total 163.612 · Fail 29.972

CANVASS RE-INSPECTION (revisita) 8,64 %
Total 35.304 · Fail 3.051

FACILITY_TYPE

Tipo de establecimiento.

LIQUOR (licor) 31,51 %
Total 1.371 · Fail 432

MOBILE FOOD PREPARER (preparación móvil) 25,04 %
Total 1.318 · Fail 330

LONG TERM CARE (cuidado prolongado) 23,22 %
Total 2.438 · Fail 566

GROCERY STORE (supermercado) 22,57 %
Total 37.996 · Fail 8.574

RESTAURANT (restaurante) 18,64 %
Total 215.024 · Fail 40.078

Para explicarlo: COMPLAINT (33,23 %) y LIQUOR (31,51 %) encabezan las salidas con ≥1.000 registros. El volumen y el porcentaje se leen juntos.

PALABRAS CLAVE DE ESTA PÁGINA

INSPECTION_TYPE

Tipo o motivo registrado de la visita.

Proyecto: 9 categorías cumplen el mínimo en la salida SQL.

FACILITY_TYPE

Clasificación del establecimiento.

Proyecto: 12 grupos cumplen el mínimo; SIN DATO no es un tipo real.

HAVING

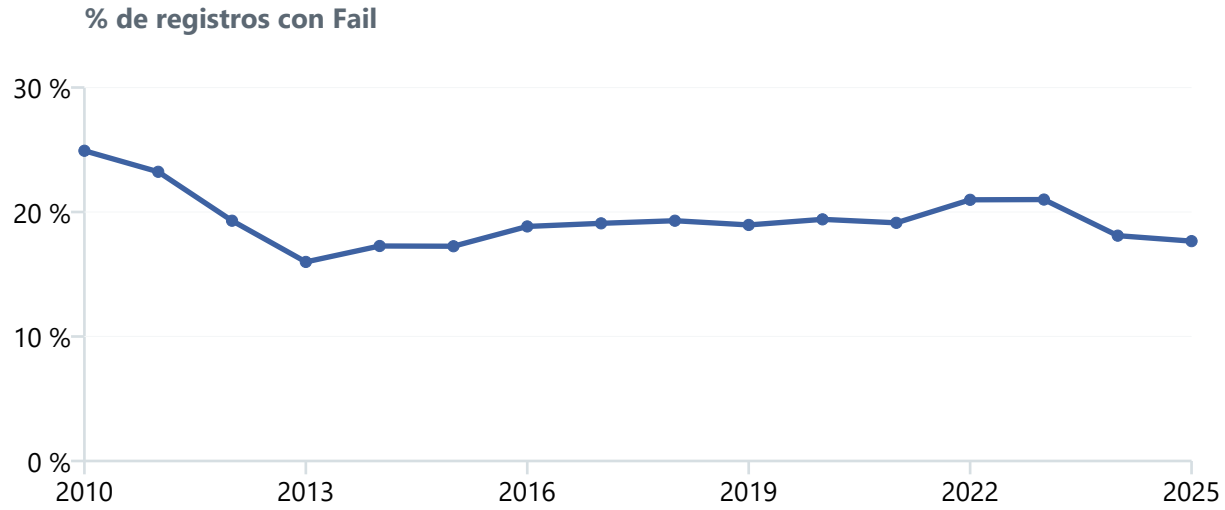
Filtra grupos después de contarlos.

Proyecto: HAVING COUNT(*) >= 1000 limita las dos comparaciones.

DATA ANALYTICS · 5 DE 5

Leer el tiempo con sus límites

El porcentaje fluctúa entre años. 2026 tiene datos hasta el 9 de octubre y se presenta por separado.



2010: **24,92 %** · 2013: **15,99 %** · 2025: **17,66 %**. No hay una disminución continua.

2026 · AÑO INCOMPLETO

18,10 %

12.612 registros · 2.283 Fail

No tiene la misma cobertura que un año completo. S1 también advierte cambios de procedimientos desde 2018.

Unidad: un local puede aparecer varias veces. Los porcentajes describen inspecciones; no establecimientos únicos.

NON-INSPECTION: 5.738 registros, 11 Fail. Se conserva, pero no se usa para concluir sobre inspecciones efectivas.

Alcance: sin causalidad. El mínimo omite 3.879 registros por INSPECTION_TYPE y 11.823 por FACILITY_TYPE de las salidas; CLEAN conserva todo.

PALABRAS CLAVE DE ESTA PÁGINA

EXTRACT

Extrae una parte de una fecha.

Proyecto: EXTRACT(YEAR...) agrupa por año de inspección.

Cobertura

Período representado por los registros.

Proyecto: 2026 termina el 9 de octubre en el conjunto usado.

NON-INSPECTION

Etiqueta con significado ambiguo.

Proyecto: Se mantiene en SQL, sin interpretarla como inspección efectiva.

Evidencia: 04analytics.sql, consulta 7 · Límite temporal adicional: portal oficial S1

TRANSICIÓN · DATA SCIENCE PENDIENTE

El siguiente paso sigue pendiente

Science recibirá los datos preparados y los hallazgos de Analytics. Aún no hay una etapa práctica desarrollada.

CLEAN

316.961 registros · 17 columnas

Tabla preparada y validada.

→

Conocimiento

19,26 % del total tiene Fail.

Diferencias entre grupos; límites documentados.

→

Data Science

ETAPA PRÁCTICA PENDIENTE

No hay modelo, métricas ni resultados que presentar.

El encadenamiento ya visible: Engineering conservó los datos y mejoró su formato; Analytics calculó indicadores e identificó asociaciones. Science ampliará la guía cuando exista trabajo real de esa etapa.

Fuentes oficiales para leer los términos del dataset

[S1] Portal Food Inspections · City of Chicago

[S2] Diccionario oficial de datos · 2 páginas

PALABRAS CLAVE DE ESTA PÁGINA

Encadenamiento
Una etapa entrega su salida a la siguiente.

Proyecto: CLEAN y los hallazgos de Analytics serán entradas de Science.

Evidencia
Salida que permite revisar una afirmación.

Proyecto: Los scripts y las salidas de Oracle respaldan los números.