

Universidad de Costa Rica

Sede del Pacífico

Bachillerato en Informática Empresarial

IF-0010 Bases de Datos II

Investigación:

Diferencias y similitudes entre Data Analytics, Data Science y Data Engineering

Integrantes:

David Mora Gómez

Fiorella Duque C5E773

Valeria Ramírez Rodríguez C5I717

Ashly Jiménez Calvo C5G203

Docente:

Máster Juan Carlos Umanzor Arguedas

II Semestre, 2026

Índice

1. Introducción 3
2. Investigación teórica 4
2.1 Marco general de Data Analytics, Data Science y Data Engineering 4
2.2 Data Analytics 5
2.3 Data Science 7
2.4 Data Engineering 9
2.5 Comparación y relación entre las tres disciplinas 11
3.Caso práctico 30

1. Introducción

En la actualidad, los datos se han transformado en un recurso principal para las organizaciones o instituciones, debido a que permiten obtener información útil para entender situaciones,identificar patrones de consumo y apoyar la toma de decisiones. Sin embargo, utilizar los datos de manera adecuada requiere de diferentes procesos y conocimiento, que permitan almacenarlos,transformarlos, analizarlos e interpretarlos. En este contexto adquieren importancia trabajos especializados como Data Engineering, Data Analytics y Data Science, las cuales participan en distintas etapas del ciclo de los datos y cumplen funciones que, aunque se encuentran relacionadas, poseen objetivos y responsabilidades particulares de cada una.

Data Engineering se encuentra vinculada con la preparación y gestión de los datos necesarios para que puedan utilizarse posteriormente. Por otra parte, Data Analytics se orienta al análisis de los datos con el propósito de obtener información que permita responder preguntas y comprender determinados comportamientos. Data Science, por su parte, emplea los datos y diferentes métodos de análisis para abordar problemas de mayor complejidad y generar conocimiento a partir de ellos. Debido a la relación existente entre estas disciplinas, es importante comprender no solamente qué hace cada una, sino también cómo se complementan y en qué aspectos se diferencian.

La presente investigación tiene como objetivo analizar las diferencias y similitudes entre Data Analytics, Data Science y Data Engineering, teniendo en cuenta sus objetivos, responsabilidades, herramientas, procesos y participación dentro del ciclo de vida de los datos. También, se busca distinguir las funciones de los roles relacionados a cada disciplina y reconocer los puntos en los que sus actividades pueden relacionarse o superponerse. De esta forma, la investigación pretende brindar una visión comparativa que permita comprender el aporte específico a cada área.

Para complementar el análisis teórico, se desarrollará un caso práctico utilizando un mismo conjunto de datos, mediante el cual se recorrerán las tres disciplinas y evidenciará el aporte que realiza cada una. Con este caso podremos observar cómo los datos pasan por diferentes etapas y cómo el trabajo realizado en una etapa sirve de base para la siguiente. Además, se documentaran las decisiones tomadas, las herramientas utilizadas, los cambios realizados sobre los datos y los

resultados obtenidos, con el propósito de mostrar de manera práctica la relación entre Data Engineering, Data Analytics y Data Science.

En conjunto, esta investigación busca demostrar que estas tres disciplinas no deben entenderse como áreas independientes, sino como componentes relacionados dentro del trabajo con datos. La comparación teórica y el desarrollo del caso permitirán comprender qué aporta cada disciplina, cómo se complementan y por qué la correcta ejecución de cada etapa puede influir en el resultado final del proceso.

2.2 Data Analytics

2.2.1 Definición y objetivo

El análisis de datos es un proceso que consiste en inspeccionar, limpiar, transformar y modelar datos para descubrir información útil. En términos sencillos, primero se revisa qué datos hay y en qué estados están: Luego, se corrigen errores o vacíos, después se organizan y adaptan para que sean manejables, y finalmente se construyen modelos que permitan entenderlos. No se trata solo de aplicar técnicas aisladas, sino de un método integral que permite interpretar datos de distintas fuentes y formatos, ya sean estructurados o no estructurados (DataCamp, s.f.).

El objetivo principal del análisis de datos es facilitar la toma de decisiones basadas en evidencia. Esto significa que las personas y las organizaciones pueden elegir mejor que hacer al contar con información concreta en lugar de guiarse sólo por la intuición (Datademia, 2022). Por ejemplo, una empresa de comercio electrónico puede analizar el comportamiento y las preferencias de sus clientes para personalizar experiencias, prever ventas y optimizar estrategias de marketing (DataCamp, s.f.). En este sentido, el análisis de datos no es un fin en sí mismo, sino una herramienta que ayuda a planificar, predecir tendencias y mejorar la eficacia en las operaciones.

Como señala Datademia (2022), la idea central es que aquello que no se mide no se puede mejorar, por lo que el análisis se convierte en algo fundamental para obtener mejores resultados. Esta idea proviene de una frase famosa de Peter Drucker: “Si no puedes medirlo, no puedes mejorarlo” (como se citó en Datademia, 2022, párr. 5). En eso consiste el análisis de datos: en tomar acciones con el objetivo de mejorar un resultado, medir después el efecto de esas acciones y comprobar si realmente se han mejorado los resultados.

Para lograr esto, el análisis no se limita a mostrar números sueltos, sino que responde a diferentes tipos de preguntas clave para entender el negocio:

Descriptivas (¿Qué pasó?): Este tipo de análisis revisa los datos para explicar lo que ha ocurrido en el pasado. Su objetivo es identificar patrones o tendencias y mostrar un panorama claro del rendimiento. Por ejemplo, en un hospital, si de repente llegan muchos pacientes a urgencias, el análisis descriptivo indica que eso está pasando y entrega datos como fechas, volúmenes y características de los pacientes. Es la base de todo análisis, porque ayuda a entender qué está sucediendo antes de buscar explicaciones más profundas (Insight Software, s.f.).

Diagnósticas (¿Por qué pasó?): Una vez que se sabe qué ocurrió, el análisis diagnóstico busca las causas. Se le conoce como "análisis de causa raíz" porque profundiza en los datos para encontrar relaciones y explicar por qué sucedió algo. Siguiendo el ejemplo del hospital, este análisis podría mostrar que todos los pacientes con fiebre, tos y fatiga tienen el mismo agente infeccioso, lo que explica el aumento repentino de ingresos. Así, no solo se describe el problema, sino que se entiende su origen (Insight Software, s.f.).

Predictivas (¿Qué pasará?): Este análisis utiliza datos históricos y modelos estadísticos para anticipar lo que podría ocurrir en el futuro. Toma la información del pasado y la aplica a la situación actual para hacer pronósticos. En el caso del hospital, podría predecir que en las próximas semanas aumentarán los ingresos en urgencias porque la enfermedad se está propagando. Esto permite prepararse con antelación y tomar decisiones más informadas (Insight Software, s.f.).

Prescriptivas (¿Qué deberíamos hacer?): El análisis prescriptivo va un paso más allá: no solo dice qué es probable que pase, sino que recomienda qué acciones tomar. Sugiere distintas opciones y explica las posibles consecuencias de cada una. En el ejemplo del hospital, podría recomendar aumentar el personal de urgencias para atender la mayor afluencia de pacientes. Este tipo de análisis ayuda a elegir el mejor camino para alcanzar los resultados deseados (Insight Software, s.f.).

Estos cuatro tipos de análisis funcionan juntos: primero se describe lo que pasó, luego se explica por qué, después se predice qué podría suceder y, finalmente, se recomienda qué hacer. Combinarlos permite a las organizaciones tomar decisiones basadas en datos y mejorar de forma continua (Insight Software, s.f.).

2.2.2 Rol y responsabilidades del Data Analytics

Un data analytics, o analista de datos, es la persona encargada de recopilar, procesar e interpretar datos para sacar conclusiones que ayuden a las empresas a tomar mejores decisiones y aprovechar oportunidades de mejora. Según Keepcoding (2025), esta labor es importante en sectores como el marketing, la tecnología, las finanzas e incluso la salud. En cierto sentido, ser analista de datos es como ser un detective que busca pistas entre grandes cantidades de información para detectar patrones y sacar conclusiones a partir de los números. Pero su trabajo no termina ahí: también debe traducir esos datos a un lenguaje comprensible para directivos, equipos de ventas o desarrolladores.

Sus principales responsabilidades según KeepCoding (2025), son:

Recolección de datos: Recopila información de diversas fuentes, como bases de datos, archivos, encuestas o sistemas de seguimiento.

Limpieza de datos: garantiza la calidad de los datos eliminando errores, duplicados e información irrelevante.

Análisis de datos: utiliza herramientas estadísticas y programas especializados para interpretar los datos y encontrar patrones, tendencias y relaciones.

Visualización de datos: crea gráficos, tablas y otras visualizaciones para presentar los hallazgos de manera clara y comprensible.

Generación de informes: prepara informes detallados donde resume los resultados y da recomendaciones específicas.

Colaboración: trabaja con otros departamentos para entender qué datos necesitan y proporcionarles la información adecuada.

Optimización de procesos: busca oportunidades para mejorar la eficiencia de los procesos a partir de todo lo anterior.

2.2.3 Herramientas y tecnologías

Para hacer su trabajo, un analista de datos no usa una sola herramienta, sino varias que se complementan entre sí. Según KeepCoding (2025), estas tecnologías se pueden agrupar según la tarea que cumplen dentro del proceso de análisis.

Consultas y base de datos

La herramienta principal aquí es SQL, un lenguaje que sirve para acceder, extraer y combinar información guardada en bases de datos. Según el Tecnológico de Monterrey (2026), muchas empresas almacenan sus datos en sistemas que solo se pueden consultar con SQL, por lo que saber usarlo le da al analista la capacidad de responder preguntas por su cuenta, sin depender de otros equipos.

Python para análisis y automatización

Python es uno de los lenguajes más usados para análisis de datos. Según el Tecnológico de Monterrey (2026), permite limpiar información, automatizar tareas, crear reportes y trabajar con bibliotecas como Pandas. El mismo artículo menciona que Pandas sirve específicamente para organizar y analizar datos.

Hojas de cálculo

Aunque parezcan básicas, Excel y Google Sheets siguen siendo útiles para exploraciones rápidas, revisiones simples y para compartir resultados con equipos que no manejan herramientas técnicas. Así lo señala el Tecnológico de Monterrey (2026), que las incluye entre las habilidades básicas del analista. Además, DataCamp (2026) indica que Excel ofrece muchas funciones para manipular, analizar estadísticamente y visualizar datos. Su sencillez y versatilidad la hacen útil tanto para tareas simples como complejas.

Visualización de datos

Para representar la información de manera clara y atractiva, se suele utilizar herramientas como Tableau o Power BI, según KeepCoding (2025). En cuanto a Power BI, DataCamp (2026) lo presenta como una herramienta de análisis empresarial creada por Microsoft. Ofrece visualizaciones interactivas con funciones de inteligencia empresarial de autoservicio y se utiliza para transformar datos brutos en información valiosa mediante paneles e informes fáciles de entender. Asimismo, DataCamp (2026) describe Tableau como una herramienta potente de visualización de datos usada en inteligencia empresarial. Permite crear paneles interactivos y compartibles que muestran tendencias, variaciones y densidad de los datos mediante gráficos.

Estadística y matemáticas

También se menciona que “Para interpretar datos con precisión y detectar correlaciones o tendencias, resulta innegociable tener unas bases firmes en estas áreas” (KeepCoding, 2025, párr. 4).

Además de estas herramientas, existen otras tecnologías especializadas que complementan el trabajo del analista de datos. Entre ellas se encuentran diferentes lenguajes de programación, bibliotecas especializadas, motores de bases de datos y almacenes de datos en la nube.

Motores de bases de datos, bibliotecas y herramientas especializadas

En el caso de Python, DataCamp (2026) señala que es un lenguaje de programación de alto nivel y de propósito general. Es muy popular entre analistas y científicos de datos porque es sencillo y fácil de leer. Además, cuenta con muchas bibliotecas, como pandas, NumPy, Matplotlib y Polars, que lo hacen muy útil para analizar y visualizar datos. Hoy en día, los flujos de trabajo en Python suelen apoyarse en asistentes de codificación con IA para generar código repetitivo y depurar scripts complejos.

En el caso de R, DataCamp (2026) lo define como un lenguaje de programación y un entorno de software libre diseñado para la estadística y los gráficos. Lo usan estadísticos y analistas de datos para crear software estadístico y analizar datos. R ofrece muchas técnicas estadísticas y gráficas, como modelos lineales y no lineales, pruebas estadísticas clásicas, análisis de series temporales y más.

Por otra parte, es importante aclarar que SQL no es un motor de base de datos en sí mismo, sino el lenguaje que utilizan estos sistemas para gestionar y manipular los datos (DataCamp, 2026).

¿Qué es un motor de base de datos?

Un motor de base de datos es el componente de software que se encarga de almacenar, procesar y proteger los datos (Microsoft, 2017). Es como el “corazón” del sistema: se ocupa de crear, leer, actualizar y eliminar la información que guardamos. Cuando hablamos de motores como MySQL o PostgreSQL, nos referimos a los sistemas concretos donde realmente se almacenan y se consultan los datos.

Estos motores se pueden dividir en dos grandes grupos según su propósito principal: los motores relacionales tradicionales, pensados para aplicaciones que necesitan guardar y consultar datos en tiempo real (como una tienda en línea o un banco), y los almacenes de datos en la nube, diseñados para analizar grandes volúmenes de información (Metabase, 2026).

Motores relacionales tradicionales

MySQL: es un motor de código abierto muy popular para aplicaciones web y comercio electrónico. Se caracteriza por ser rápido y fácil de usar, y lo utilizan empresas como Facebook o Twitter (MySQL, s.f.).

PostgreSQL: también es de código abierto, pero se distingue por su gran fiabilidad y su capacidad para manejar datos complejos. Es ideal para aplicaciones que necesitan integridad y escalabilidad, como sistemas financieros o de análisis avanzado (PostgreSQL, s.f.).

Microsoft SQL Server: es el motor de Microsoft, muy utilizado en empresas que trabajan con entornos Windows. Ofrece herramientas integradas de inteligencia empresarial y análisis de datos (Microsoft, s.f.).

Oracle Database: es uno de los motores más potentes y completos del mercado. Se usa en aplicaciones críticas donde la seguridad, el rendimiento y la escalabilidad son fundamentales (Oracle, s.f.).

Almacenes de datos en la nube (data warehouses)

A medida que los datos crecen y las empresas necesitan analizarlos de forma masiva, aparecen los almacenes de datos en la nube. Estos motores están diseñados para consultas analíticas sobre millones o miles de millones de registros (Metabase, 2026).

Google BigQuery: es un almacén de datos totalmente gestionado por Google. Permite analizar datos a gran escala sin necesidad de administrar servidores, y es ideal para proyectos de análisis en tiempo real (Google Cloud, s.f.).

Snowflake: se caracteriza por separar el almacenamiento del cómputo, lo que permite escalar de forma flexible y pagar solo por lo que se usa. Es muy utilizado para análisis de datos y aplicaciones de inteligencia artificial (Snowflake, s.f.).

Amazon Redshift: es el almacén de datos de Amazon Web Services. Está diseñado para consultas analíticas sobre petabytes de información y ofrece un rendimiento muy alto gracias a su procesamiento masivamente paralelo (Amazon Web Services, s.f.).

2.2.4 Proceso de trabajo y metodologías

Cuando alguien empieza en análisis de datos, una de las primeras cosas que aprende es que el trabajo no ocurre de una sola vez. No es sentarse, abrir un archivo y sacar conclusiones al instante. Hay un proceso, y ese proceso se repite cada vez que se aborda un proyecto nuevo.

Según KeepCoding (2025), el flujo diario de un analista sigue cuatro momentos principales. Primero está la extracción y preparación: se identifican las fuentes, se limpian duplicados, se corrigen valores vacíos. Es la parte menos vistosa pero la que consume más tiempo. Después viene el análisis de datos, donde se buscan patrones y relaciones entre los datos. Luego la visualización, que consiste en armar gráficos para que otros entiendan lo que se encontró. Y finalmente la generación de informes: traducir los hallazgos en recomendaciones concretas para el negocio, como reducir costos o mejorar un producto.

Pero más allá del día a día, existe algo más estructurado: las metodologías formales para gestionar proyectos de datos. La más usada se llama CRISP-DM. Según una tesis de la Pontificia Universidad Católica del Perú (Olivera Cokan, 2024), CRISP-DM es el estándar más adoptado en la industria porque es flexible y se adapta a distintos sectores. El mismo trabajo menciona que también existen SEMMA y KDD, pero se usan más en contextos específicos.

CRISP-DM organiza un proyecto en seis etapas: entender el negocio, entender los datos, prepararlos, construir modelos, evaluarlos y finalmente desplegar la solución. No es una receta rígida: uno puede volver a etapas anteriores si algo no funciona. Por eso la tesis de Olivera Cokan (2024) señala que muchas organizaciones adaptan CRISP-DM a sus necesidades en lugar de aplicarlo tal cual.

Entregables

El trabajo de un Data Analytics no termina cuando se analizan los datos, sino que se materializa en una serie de productos concretos que pueden ser revisados, compartidos y utilizados

por otras personas dentro de la organización. A estos productos se les denomina entregables. En este apartado se describen los principales entregables que un Data Analyst produce en su trabajo.

Dashboards e informes

Los dashboards son herramientas visuales e interactivas que reúnen en una sola pantalla los indicadores más importantes de una organización. Según Microsoft (2025), la diferencia principal entre un dashboard y un informe es el lugar donde se construyen: los dashboards se crean en el servicio de Power BI y se forman con piezas que provienen de uno o varios informes, mientras que los informes se elaboran en Power BI Desktop y permiten un análisis más detallado. Para que un dashboard sea útil, debe ser claro, interactivo, actualizarse con cierta frecuencia y tener un diseño atractivo (Microsoft, 2025). Los informes, por su parte, presentan la información en varias páginas y sirven como paso previo para construir un dashboard (Microsoft, 2025).

Documentación de datos

El diccionario de datos es un documento que explica qué significa cada variable de una base de datos y cómo debe interpretarse. Según la Oficina Nacional de Estadística de República Dominicana (2025), elaborar un diccionario de datos requiere seguir varias etapas: planificar, definir técnicamente las variables, construirlo, difundirlo, mantenerlo y evaluarlo. Además de este diccionario, la documentación de las fuentes y de las transformaciones permite que tanto analistas como personas no especializadas entiendan de dónde vienen los datos y qué se hizo con ellos. Esto ayuda a que el trabajo sea más transparente y confiable (Oficina Nacional de Estadística de República Dominicana, 2025).

Consultas y scripts reutilizables

Los notebooks, como los de Jupyter, son herramientas que combinan texto explicativo y código en un mismo documento, lo que facilita repetir el análisis. Según MySQL (s.f.), un notebook está formado por celdas ejecutables, bloques de texto y resultados que se muestran directamente, y resulta apropiado para construir flujos de trabajo que se pueden repetir y para presentar resultados de forma más ordenada que un archivo SQL o Python común.

Presentaciones ejecutivas

Presentar resultados a personas que no son especialistas en datos requiere resumir hallazgos complejos en mensajes claros que ayuden a tomar decisiones. Según Microsoft (2026), una presentación ejecutiva se diferencia de una revisión exhaustiva de datos porque debe ser breve, estar organizada como una historia y orientarse a la acción. En este contexto, es útil porque convierte los números en una narrativa que lleva a una conclusión concreta.

Consumidores

El trabajo del análisis de datos no queda guardado solo para quien lo hace, sino que sus resultados y conclusiones son aprovechados por distintas personas y grupos dentro y fuera de una organización. Cada uno de estos sectores utiliza la información de manera distinta para cumplir con sus metas diarias y de planificación:

Equipos de negocio

Estos grupos utilizan la información para entender el día a día del negocio. Por ejemplo, según Intone (2025), los equipos de marketing y ventas analizan el comportamiento de los clientes para mejorar campañas, operaciones busca solucionar retrasos o ineficiencias en los procesos, y finanzas revisa los números para cuidar el presupuesto y las proyecciones.

Dirección y alta gerencia

Los líderes principales y directivos necesitan ver informes claros y resumidos para tomar decisiones estratégicas importantes. Como señalan los autores de IbisWorld (2024), este grupo tiene un alto nivel de poder e influencia sobre el rumbo de la organización, por lo que dependen de estos datos para planificar el futuro y orientar los recursos de forma correcta sin tener que adivinar.

Equipos de producto y desarrollo

Estos equipos necesitan saber cómo interactúan las personas con los servicios o aplicaciones para decidir qué mejoras o funciones nuevas, se deben programar primero. Según Khatu (2026), un analista especializado en producto ayuda a estudiar estos recorridos para que los desarrolladores sepan exactamente en qué trabajar.

Equipos de datos

Según Brickclay (2026), son los profesionales encargados de trabajar con los datos a lo largo de diferentes etapas. Los ingenieros de datos preparan, integran, limpian y estructuran la información para que pueda ser utilizada. Los científicos de datos analizan esos datos para encontrar patrones y desarrollar modelos predictivos, mientras que los analistas y profesionales de BI transforman los resultados en reportes, visualizaciones y herramientas que facilitan la toma de decisiones en la organización.

Clientes externos

Los resultados del análisis y los reportes pueden compartirse con personas externas a la organización, como clientes, consultores o socios. Según Domo (2026), las herramientas de reportes en la nube permiten distribuir dashboards, visualizaciones e informes de forma automatizada o mediante acceso directo, facilitando que estas audiencias conozcan información relevante sobre el desempeño y los resultados de la organización.

2.3 Data Science

2.3.1 Definición y objetivo

La ciencia de datos (Data Science) es el estudio que hace uso de muchas disciplinas cuyo fin es la extracción de información útil y generar nuevo conocimiento a partir de la manipulación de los conjuntos de datos. Según Smith (2006) y Yau (2009), como se citó en Cao (2017), la ciencia de datos ha generado intensos debates sobre su constitución como disciplina académica multidisciplinaria que abarca desde la estadística y la computación hasta el diseño gráfico y la interacción humano-computadora (pp. 2-3).

Entre los distintos campos involucrados se encuentran la matemática y la estadística, fundamentales para que las conclusiones que surgen de la aplicación de esta ciencia sean lo más precisas posible con respecto al mundo real, los procesos sean optimizados y se manejen adecuadamente situaciones que pueden llegar a ser inciertas, como cuando los datos se encuentran incompletos; por otra parte, se encuentran los campos relacionados con la computación y programación cuando se utilizan diferentes lenguajes y sistemas para la consulta y gestión de datos (como el ya establecido y reconocido SQL, acompañado de un sistema gestor de bases de datos),

así como para la implementación de algoritmos, como podría ser el desarrollo de uno de ellos en Python. Además, en el ejercicio de la ciencia de datos, se debe tomar en cuenta el contexto y las características de la organización o negocio en el cual se centra.

Un aspecto muy importante sobre la ciencia de datos es la identificación y análisis de patrones, lo cual es muy útil en el campo de los negocios. Por ejemplo, según Kelleher y Tierney (2018), mediante la ciencia de datos es posible extraer distintos tipos de patrones que permiten identificar grupos de clientes con comportamientos y gustos similares (p. 2).

Entonces, se puede decir que el objetivo de la ciencia de datos es transformar grandes volúmenes de datos que quizás no se encuentran inicialmente estructurados y no se le pueden extraer una interpretación sólida en conjunto, en información rentable que ayuda a una organización a comprender mejor cómo funcionan sus operaciones, cómo suceden los problemas y realizar una proyección a futuro sobre qué puede suceder y decidir cuál es la mejor ruta de acción. Gracias a la ciencia de datos, se tiene una idea fundamentada sobre lo que podría suceder y no solo suposiciones. De esta manera, “la ciencia de datos implica extraer información útil de los datos para ayudar en la toma de decisiones” (Provost y Fawcett, 2013).

2.3.2 Rol y responsabilidades del Data Scientist

Un científico de datos (Data Scientist) es un profesional en la ciencia de datos, es decir, es quien se encarga de extraer la información, generar conocimiento y crear modelos de predicción útiles a partir de cantidades masivas de datos utilizando sus distintas capacidades en las múltiples áreas mencionadas como parte de la ciencia de datos, como la matemática y la programación. Algunos de los resultados que busca obtener un científico de datos, son estrategias para determinar posibles tendencias en el futuro, la automatización de procesos y resolución de problemas en el negocio o organización que se encuentra operando. La demanda por este rol en el sector empresarial llegó a crecer mucho, lo cual representó un reto debido a que la cantidad de científicos de datos era suficiente. Según Davenport y Patil (2012), los científicos de datos son aquellos profesionales capaces de extraer respuestas a preguntas clave de negocio a partir de la inmensa cantidad de información no estructurada que existe en la actualidad, siendo la escasez de este talento el principal obstáculo para las organizaciones (p. 72).

Para comprender cómo se organiza el trabajo de un científico de datos y qué responsabilidades posee, hay que mencionar lo que se conoce como ciclo de vida de la ciencia de datos. Este ciclo de vida se define como un conjunto de pasos u operaciones establecidos estratégicamente que busca tomar un problema de negocio y elaborar una solución lógica, comprensible, eficiente y consistente en el tiempo para ese problema específico. El modelo tradicional incluye distintas etapas, las cuales no necesariamente deben ser completadas una después de otra, ya que en ocasiones concretas se podría requerir ir de vuelta a alguna etapa ya abordada anteriormente. Las etapas del ciclo de vida de la ciencia de datos definidas son: comprensión de las necesidades o problema del negocio, recolección y comprensión de los datos, preparación y análisis de los datos, modelado, evaluación, despliegue y mantenimiento.

En la etapa de comprensión de las necesidades o problemas del negocio, el científico de datos debe determinar los pasos a seguir para llegar a las metas que el negocio desea alcanzar, identificando las métricas que busca trabajar. Según Wirth y Hipp (2000), la fase inicial de la metodología se enfoca en comprender los objetivos y requerimientos del proyecto desde una perspectiva de negocio, para luego transformar este conocimiento en la definición de un problema de minería de datos y en un plan preliminar de trabajo diseñado para alcanzar dichos objetivos (p. 31). En esta etapa, el científico de datos formula cinco preguntas: en primer lugar, "¿Qué sucede?" corresponde al análisis descriptivo para entender la situación actual de una organización mediante el resumen de datos e informes gráficos; en segundo lugar, "¿Por qué sucedió?" es el análisis diagnóstico, importante para descubrir la raíz de un problema o éxito mediante la identificación de patrones y relaciones de causa y efecto; en tercer lugar, "¿Qué sucederá?" representa el análisis predictivo, cuya importancia radica en permitir la anticipación a problemas futuros estimando tendencias y comportamientos mediante modelos estadísticos; "¿A qué se quiere llegar?" es el análisis estratégico, para establecer metas claras y alinear el trabajo técnico con la visión y los indicadores de éxito del negocio. Finalmente, "¿Qué se debe hacer?" es la pregunta prescriptiva, la etapa de mayor valor que convierte todo el conocimiento previo en recomendaciones concretas y rutas de acción para aprovechar oportunidades o disminuir riesgos.

En la etapa de recolección y comprensión de los datos, el científico de datos identifica dónde se encuentra la información necesaria para responder a las preguntas planteadas. Consulta las bases de datos, las cuales pueden ser o no relacionales, busca archivos locales, utiliza APIs,

entre otras acciones orientadas a obtener la cantidad total de datos requerida. Seguido de esto, se encuentra la etapa de preparación y análisis de los datos, en la cual el científico de datos se encarga de corregir los registros incompletos, eliminar datos duplicados, y elegir qué hacer con datos nulos. Además, busca maneras de moldear los datos en formatos fácilmente manejables para los algoritmos que se utilicen durante la resolución del problema. Según Wirth y Hipp (2000), las tareas de preparación de datos suelen realizarse múltiples veces y no siguen un orden preestablecido, abarcando desde la selección de tablas, registros y atributos, hasta la limpieza de datos, la construcción de nuevas variables y la transformación de la información para las herramientas de modelado (p. 31).

Durante la etapa del modelado, el científico de datos selecciona y entrena herramientas y algoritmos adecuados a la naturaleza de aquello que se desea resolver, en los cuales también involucra los datos recolectados para tal entrenamiento y realización de pruebas.

Posteriormente, se realiza la etapa de evaluación, en la cual el científico de datos toma los resultados obtenidos y evalúa el rendimiento y eficiencia en el procedimiento, así como también verifica que el modelo se encuentre funcionando correctamente, sin problemas como el sobreajuste. Además, compara los resultados con aquello que se esperaba bajo los criterios del negocio que fueron definidos durante la primera etapa del ciclo de vida.

En la etapa del despliegue, el científico de datos toma el modelo ya entrenado y probado y lo conecta con los sistemas de la empresa; el algoritmo construido se convierte en una aplicación. Luego de esta etapa, lo que continúa es el mantenimiento, en el cual el científico de datos supervisa de forma periódica el modelo y su desempeño, identificando y actuando si ocurre algún desajuste que pueda afectar la eficiencia o precisión de sus métodos y resultados. También entrena constantemente el algoritmo ante la entrada de nuevos datos. Existen distintos tipos de consumidores que se benefician de lo que surge de esta etapa, los cuales varían de acuerdo a su rol en la organización, su nivel de conocimiento técnico y de qué manera aprovechan estas aplicaciones:

Ejecutivos y Altos Cargos de un Negocio

Este grupo incluye a directores, gerentes generales y líderes estratégicos que necesitan visión global sin entrar en detalles técnicos. Como destacan Few (2013) y Davenport (2018), su

consumo se centra en paneles de control interactivos, resúmenes ejecutivos e indicadores clave de rendimiento para tomar decisiones de alto nivel, evaluar el rendimiento general de la empresa y definir la dirección estratégica del negocio.

Usuarios y Departamentos Operativos

Comprende a los equipos de marketing, ventas, finanzas, recursos humanos o atención al cliente que integran las soluciones de datos en sus tareas cotidianas. Al respecto, Provost y Fawcett (2013) señalan que estos usuarios consumen los datos a través de reportes recurrentes, alertas automáticas o herramientas de recomendación que les ayudan a optimizar sus actividades diarias, como segmentar clientes o ajustar precios en tiempo real.

Desarrolladores y Equipos de Ingeniería

Son los encargados de integrar, mantener o escalar las soluciones creadas por el científico de datos dentro de la infraestructura tecnológica de la organización. Según Treveil et al. (2020), su consumo se da mediante interfaces de programación de aplicaciones, servicios web y modelos encriptados o empaquetados, asegurando que los algoritmos funcionen de forma estable, segura e integrada en las aplicaciones o software finales.

Clientes

Son las personas que interactúan directamente con los productos de software o servicios que incorporan los modelos de datos. Según explican Russell y Norvig (2020), estos usuarios consumen estos desarrollos de manera transparente e implícita a través de funciones como sistemas de recomendación de contenidos, asistentes virtuales, filtros de correo no deseado o estimaciones automáticas de tiempos de entrega, mejorando su experiencia de uso sin necesidad de interpretar datos directamente.

Analistas y Científicos de Datos

Son profesionales del mismo ámbito que utilizan el trabajo desarrollado como base para otras investigaciones, auditorías o nuevos modelos. De acuerdo con Kim et al. (2016), consumen código fuente, repositorios, documentación técnica, conjuntos de datos procesados o modelos preentrenados, lo que les permite validar la metodología empleada, reproducir resultados o seguir construyendo más soluciones y más complejas sobre esa misma estructura.

2.3.3 Herramientas y tecnologías

En la ciencia de datos, las herramientas utilizadas se seleccionan según la etapa del ciclo de vida en la que se esté trabajando, ya que hay muchas de ellas que funcionan para acciones muy específicas; tenemos aquellas que son para el acceso y manipulación de los datos, por ejemplo, y aquellas que son para la construcción del modelo algorítmico para la resolución del proyecto.

Tenemos, en primer lugar, lo que son los lenguajes de programación, entre los cuales se encuentran Python, sumamente utilizado y estandarizado a nivel industrial el cual se caracteriza por poseer una sintaxis simple y fácil de aprender para muchos programadores, utilizado en la ciencia de datos para los algoritmos y modelos de producción que corresponden a la etapa de modelado. La ventaja de Python radica en que "es un lenguaje de alto nivel ya que contiene implícitas algunas estructuras de datos como listas, diccionarios, conjuntos y tuplas, que permiten realizar algunas tareas complejas en pocas líneas de código y de manera legible" (Challenger Pérez et al., 2014, p. 3). También se encuentra R, un lenguaje muy útil en estos contextos para la parte estadística en el análisis de datos.

También se puede hablar de aquellos lenguajes como SQL, cuyo enfoque es la consulta estructurada de los datos, el cual resulta indispensable en el área de ciencia de datos. SQL proporciona una gran variedad de recursos para consultas de datos en bases relacionales, tanto sencillas como aquellas que son complejas y requieren ya sea combinaciones entre datos de diferentes contextos o filtros muy específicos. Cabe mencionar, además, la combinación de Julia / Scala, siendo respectivamente un lenguaje que incluye sencillez de escritura con velocidad de ejecución alta y otro un lenguaje para trabajar con eficiencia con volúmenes de datos que sobrepasa la capacidad de una sola computadora y en su lugar, se encuentran almacenados en muchos servidores. Según Pal et al. (2024), el lenguaje de programación Julia fue creado principalmente para superar las deficiencias de otros lenguajes científicos como Python, R y MATLAB, los cuales suelen presentar limitaciones al procesar grandes volúmenes de datos y cálculos matemáticos complejos, convirtiendo a Julia en una opción destacada para la computación científica y el aprendizaje automático gracias a su simplicidad y alto rendimiento (p. 144).

En la ciencia de datos también son relevantes los motores de bases de datos y almacenamiento. Entre los motores de bases de datos se encuentran aquellos que son relacionales

y los que no, como los columnares. Y se tiene lo que son los motores de almacenamiento para guardar y procesar volúmenes muy grandes de datos a nivel empresarial.

Entre los motores relacionales, se encuentran PostgreSQL, MySQL, SQL Server y Oracle, para consultar y estructurar datos relacionales de transacciones. Las bases de datos relacionales tradicionales como PostgreSQL, MySQL, SQL Server y Oracle, que utilizan el lenguaje SQL, siguen siendo fundamentales para las operaciones transaccionales gracias a que garantizan la integridad y consistencia de los datos mediante las propiedades ACID (Silberschatz et al., 2020). Por otra parte, se encuentran aquellos NoSQL, tales como los documentales como MongoDB, o los columnares como Cassandra, A diferencia de los modelos relacionales rígidos, los sistemas NoSQL como MongoDB (orientado a documentos) y Apache Cassandra (columnar) se diseñaron para escalar de manera horizontal, ofreciendo alta velocidad de escritura y flexibilidad en el manejo de grandes volúmenes de datos no estructurados o semiestructurados (Sadalage & Fowler, 2013). Con respecto a los sistemas de almacenamiento, se dispone de aquellos como Snowflake o Google BigQuery, que soportan el almacenamiento de cantidades de datos sumamente grandes.

En la ciencia de datos, se utilizan muchas bibliotecas y librerías cuando se construyen los algoritmos con lenguajes como Python o R, para resolver distintos problemas con conocimientos de áreas como álgebra lineal o cálculo; entre ellos, se puede mencionar Pandas o NumPy. No solo para el análisis de datos se utilizan estos recursos; para una clara visualización de los datos, se emplean herramientas para hacer de esta experiencia algo más comprensible e interactivo. Por ejemplo, Matplotlib (propia de Python) o ggplot2 (propia de R). En el análisis de datos moderno, el uso de Python y R se fundamenta en bibliotecas vectoriales y matriciales como NumPy y Pandas, las cuales facilitan la manipulación, limpieza y estructuración de conjuntos de datos complejos (McKinney, 2018). Las bibliotecas o librerías también son usadas para el aprendizaje profundo de un algoritmo, como Scikit-learn o XGBoost. Para el desarrollo de modelos predictivos y aprendizaje automático, el ecosistema abarca desde algoritmos tradicionales estandarizados en Scikit-learn (Pedregosa et al., 2011) hasta técnicas avanzadas de potenciar árboles (*gradient boosting*) como XGBoost, optimizado para ofrecer alto rendimiento y eficiencia computacional (Chen & Guestrin, 2016).

Como parte del despliegue del modelo se utilizan también programas o plataformas para construir, probar y entregar el proyecto. Por ejemplo, están los entornos de desarrollo; un ejemplo

de esto es Visual Studio Code, muy adecuado para proyectos de software de un mediano o gran tamaño. Los entornos se utilizan también para simplificar el manejo de datos distribuidos en más de un servidor, como Apache Spark, que distribuye los datos y el trabajo de ellos en distintas computadoras para un procesamiento más óptimo. Para la organización del tiempo y la automatización se utilizan programas como MLFlow, que funciona para llevar un registro de las veces que se ha probado ejecutar un algoritmo y los datos que se utilizaron; también está ApacheAirflow, el cual tiene la función de poder establecer horas específicas para que un algoritmo realice una determinada tarea, como podría ser cargar nuevos datos o limpiarlos. En el ámbito de MLOps, herramientas como MLflow actúan como bitácoras para registrar parámetros, métricas y artefactos de cada experimento, mientras que orquestadores como Apache Airflow automatizan y programan los flujos de trabajo ETL y el reentrenamiento periódico de los algoritmos (Treveil et al., 2020).

2.3.4 Proceso de trabajo y metodologías

Tal y como se mencionó anteriormente, el ciclo de vida de la ciencia de datos es esencial en este campo y es parte de los procesos de trabajo y metodologías en la ciencia de datos. Este ciclo de vida se acopla, por lo general, al procedimiento CRISP-DM(Cross-Industry Standard Process for Data Mining), creado en 1996 para ofrecer una estructura estándar para el sector industrial que se centra en los objetivos del negocio. Como destacan Wirth y Hipp (2020), este marco proporciona una estructura no rígida e iterativa que abarca desde la comprensión del negocio hasta el despliegue de los modelos. No es la única metodología, ya que mucho de lo que se debe tomar en cuenta para implementar una de ellas es el origen y el contexto del proyecto, pero sí es la más popular.

Otra metodología existente es SEMMA (Sample, Explore, Modify, Model, Assess), desarrollada por SAS Institute, la cual se caracteriza por su enfoque en el análisis y modelado, quedando en un plano más secundario la profundización en las necesidades del negocio. Como señalan Azevedo y Santos (2008), mientras que marcos como CRISP-DM priorizan la comprensión del contexto empresarial, SEMMA centra su flujo estructurado principalmente en el ciclo técnico de datos (muestreo, exploración, modificación, modelado y evaluación), asumiendo que los objetivos del negocio ya han sido previamente definidos.

Se encuentra también, la metodología KDD (Knowledge Discovery in Databases) que surgió a inicios de los años 90 como un marco enfocado en el descubrimiento de patrones a partir de grandes volúmenes de datos. Como señalan Fayyad et al. (1996), este proceso sigue una secuencia estructurada basada en el método científico que abarca desde la selección, limpieza, integración y transformación de los datos, pasando por la minería de datos propiamente dicha, hasta la interpretación y evaluación final de los hallazgos.

Existe una metodología, además, que toma el modelo CRISP-DM y lo enriquece para adaptarlo a las necesidades empresariales modernas. Esta es TDSP (Team Data Science Process), introducida por Microsoft en 2017. Según explican Saltz y Shamshurin (2019), este marco toma la estructura cíclica de procesos tradicionales como CRISP-DM y la integra con prácticas de desarrollo ágil (Scrum/Kanban) y MLOps, lo que facilita la colaboración entre equipos multidisciplinarios, la estandarización de artefactos de código y el despliegue eficiente de modelos en arquitecturas en la nube.

A partir de las metodologías anteriores, un científico de datos puede brindar a una organización los resultados de estos procedimientos en forma de distintos tipos de proyectos entregables, los cuales pueden ir desde modelos algorítmicos que generan predicciones de comportamiento hasta estrategias para la toma de decisiones.

En primer lugar, el entregable más complejo que un científico de datos puede entregar es un modelo de Machine Learning, el cual consiste en algoritmos entrenados y desplegados para automatizar predicciones o clasificaciones en tiempo real o en partes. Estos proyectos suelen entregarse como servicios backend mediante APIs REST para evaluar eventos al instante (como, por ejemplo, detección de fraude), integrarse en motores de recomendación para plataformas digitales o acompañarse de pipelines de MLOps que supervisan de forma continua el rendimiento del modelo para reentrenarlo cuando los datos cambian (Treveil et al. 2020).

Otras herramientas útiles que provee un científico de datos, son componentes interactivos o dashboards, los cuales pueden facilitar en gran medida la inserción de los usuarios del negocio o en general aquellos quienes se encargan de tomar decisiones. Como explican Few (2013) y Sievert (2020), estas soluciones adoptan la forma de aplicaciones web (desarrolladas con herramientas como Streamlit o Shiny) que permiten a los equipos simular varios escenarios en entornos de operación, así como tableros dinámicos en Power BI o Tableau que integran

proyecciones predictivas para convertir resultados matemáticos en interfaces de consulta intuitivas.

Detrás de cada modelo existe otro tipo de entregable, el cual es una base técnica de pipelines de datos y código de mantenimiento, donde se entrega software estructurado, limpio y listo para ser usado en sistemas reales. Según explican Sculley et al. (2015) esto abarca desde procesos para automatizar la extracción y limpieza de grandes volúmenes de datos mediante herramientas como Python o SQL, hasta el uso de repositorios organizados en Git y contenedores con Docker, garantizando así que el trabajo sea ordenado, fácil de mantener y reutilizable.

En proyectos donde la prioridad no es programar software sino orientar decisiones de negocio, un científico de datos entrega análisis detallados e informes de diagnóstico. Provost y Fawcett (2013) afirman que estos entregables responden preguntas clave de la organización mediante estudios para agrupar clientes según sus comportamientos, evaluaciones de experimentos para probar cambios en productos, o modelos predictivos para entender por qué los usuarios cancelan un servicio y cuánto valor aportan a la empresa a lo largo del tiempo.

Finalmente, para asegurar que las soluciones puedan ser revisadas y entendidas por otros equipos, el científico de datos entrega documentación técnica y ejecutiva. De acuerdo con Mitchell et al. (2019), esto comprende desde fichas descriptivas del modelo que explican cómo funciona el algoritmo, sus niveles de precisión y sus posibles limitaciones, hasta presentaciones ejecutivas que traducen los datos matemáticos en resultados de impacto financiero para la empresa.

2.4 Data Engineering

2.4.1 Definición y objetivo

Ingeniería de datos (Data Engineering) se enfoca principalmente al diseño, construcción, implementación y mantenimiento de los sistemas y procesos que permiten transformar datos en bruto en información consistente y confiable, los datos en bruto son aquellos que se obtienen directamente de una fuente y que aún no han pasado por procesos de limpieza, transformación u organización para su análisis. Por esta razón, la ingeniería de datos no trabaja solamente con los datos, sino que también con la infraestructura necesaria para recopilarlos, procesarlos y transformarlos. Reis y Housley plantean que esta disciplina comprende el desarrollo, implementación y mantenimiento de sistemas capaces de producir datos consistentes y de calidad

tales como lo es la analítica y el aprendizaje automático (Reis & Housley, como se citó en Heck, 2024).

El objetivo principal de la ingeniería de datos es lograr que los datos estén disponibles, sean confiables, y se encuentren listos para su utilización. Para lograr esto se diseñan infraestructuras para así tener un mejor manejo sobre los datos, junto con procesos los cuales nos permiten recopilar, transformar y almacenar los datos de una manera organizada, facilitando así, el uso de estos datos en áreas como Data Analytics, Business Intelligence, Data Science o Machine Learning (University of the West of Scotland [UWS], s. f.).

2.4.2 Rol y responsabilidades del Data Engineer

Un Ingeniero de Datos (Data Engineer) cumple un rol bastante técnico dentro de un equipo de datos, ya que se encarga de diseñar, construir y mantener la infraestructura que permite mover información, una de sus principales responsabilidades consiste en desarrollar y operar data pipelines, los cuales permiten recopilar, procesar, transformar, almacenar y entregar los datos de forma organizada y confiable (Wells, 2020).

Entre sus responsabilidades se encuentra el tener que garantizar que los datos tengan niveles adecuados de calidad, consistencia y disponibilidad, así como también debe administrar y supervisar tanto las estructuras donde serán almacenados los datos, como también los procesos que los transportan. Algo importante a tener en cuenta es que también puede participar en la implementación técnica de políticas relacionadas con seguridad, gobernanza y trazabilidad de datos (University of the West of Scotland [UWS], s. f.).

Para realizar su trabajo un Ingeniero de datos (Data Engineer) recibe datos de distintas fuentes como base de datos, aplicaciones, APIs, archivos o dispositivos. A partir de esta información obtenida, se encarga de producir canalizaciones funcionales, estructuras de almacenamiento y conjuntos de datos limpios, integrados y preparados para su uso posterior (Wells, 2020; University of the West of Scotland [UWS], s. f.).

Los resultados del trabajo de un Ingeniero de datos son utilizados principalmente por los Data Analyst, profesionales de Business Intelligence y Data Scientists, quienes dependen de datos confiables y accesibles para realizar análisis, generar visualizaciones o desarrollar modelos.

Como podemos observar el Ingeniero de Datos facilita al Data Analyst y Data Scientist ya que les proporciona información previamente procesada y preparada para su utilización, Esto hace

que estos profesionales puedan enfocarse en el análisis, interpretación o desarrollo de modelos, en lugar de gastar tiempo con problemas relacionados con la preparación de los datos (Heck, 2024)

2.4.3 Herramientas y tecnologías

La Ingeniería de datos (Data Engineering) utiliza distintos lenguajes y tecnologías para gestionar el movimiento, procesamiento y almacenamiento de la información. Los lenguajes más utilizados son SQL y Python, SQL se utiliza principalmente para hacer consultas, estructurar y transformar los datos que se encuentran en la base de datos y sistemas analíticos, mientras que Python se utiliza para agilizar procesos, desarrollar data pipelines personalizados e integrar distintas fuentes de información (Wells, 2020; University of the West of Scotland [UWS], s. f.; Heck, 2024).

En cuanto al almacenamiento, los Ingenieros de Datos trabajan con diferentes tipos de sistemas según las necesidades del proyecto, por lo que utilizan bases de datos relacionales, bases NoSQL, Data Warehouses, Data Lakes entre otras, también se utilizan servicios de almacenamiento como la nube en Amazon S3, Azure Storage o Google Cloud Storage, todo esto mayormente cuando se quiere manejar grandes volúmenes de información de manera escalable (Wells, 2020; UWS, s. f.).

Para el procesamiento de grandes cantidades de datos emplean tecnologías como Apache Spark, herramienta la cual principalmente realiza los procesos distribuidos y por lotes, mientras que por otro lado tenemos Apache Flink el cual es una herramienta para escenarios de procesamiento continuo. Además, procesos como el ETL y ELT forman parte importante en el trabajo de un Ingeniero de datos, ya que permiten extraer, transformar y cargar la información según la arquitectura a utilizar (Mazumdar et al., 2023; Wells, 2020).

Un dato importante a conocer es que algunas de estas herramientas mencionadas son compartidas con otras disciplinas. Por ejemplo, SQL y Python son utilizados tanto en Data Analytics como en Data Science, aunque con objetivos diferentes. En Data Engineering se utilizan principalmente para construir y automatizar procesos de datos (Heck, 2024; UWS, s. f.).

2.4.4 Proceso de trabajo y metodologías

El proceso de trabajo en Ingeniería de Datos suele seguir una serie de etapas que permiten transformar datos en bruto en información preparada para su utilización. Este proceso inicia con la generación de los datos en diferentes fuentes, seguidamente estos datos son ingresados hacia el entorno donde serán procesados, almacenados y transformados. Una vez que los datos han sido limpiados, organizados y válidos, estos son puestos a disposición de otros usuarios o sistemas para su respectivo análisis o utilización (Reis & Housley, como se citó en Heck, 2024; UWS, s. f.).

Dentro de este proceso, uno de los enfoques más conocidos para trabajar con los datos es el ETL, enfoque el cual consiste en extraer los datos, transformarlos y posteriormente cargarlos en el sistema de destino. Por otro lado, ELT realiza primero la extracción y carga de los datos para posteriormente realizar las transformaciones dentro del sistema donde fueron almacenados. Existen también enfoques de procesamiento por lotes o batch, donde los datos se procesan en grupos determinados y procesamiento en tiempo real o streaming, donde los datos son procesados conforme se van generando (Wells, 2020; Mazumdar et al., 2023).

DataOps es otro enfoque utilizado en la Ingeniería de Datos el cual busca automatizar y coordinar diferentes etapas del ciclo de vida de los datos, haciendo que la entrega de información sea más fácil, más rápida y confiable, durante todo este proceso se debe tomar en cuenta aspectos como la calidad de los datos, seguridad, gobernanza, monitoreo y orquestación de los procesos (Heck, 2024; Wells, 2020).

2.5 Comparación y relación entre las tres disciplinas

Data Analytics, Data Science y Data Engineering son disciplinas relacionadas que trabajan con datos dentro de las organizaciones. Aunque compartan similitudes como conocimientos, procesos y herramientas, cada una posee objetivos y responsabilidades particulares. Data Engineering se encarga principalmente de armar y mantener sistemas en pie que permitan recopilar, procesar y almacenar los datos; Data Analytics se orienta a examinar e interpretar la informaciòn y datos para responder preguntas y apoyar la toma de decisiones; mientras Data Science usa mètodos estadìsticos, matemàticos y computacionales para descubrir patrones , desarrollar modelos predictivos y resolver problemas complejos.

Estas disciplinas permiten comprender que el aprovechamiento de los datos no depende solamente de analizar, sino que contar con una infraestructura adecuada y aplicar métodos que den

resultados seguros. De esta manera, las tres áreas contribuyen a formar los datos en recursos útiles para las compañías , aunque sus aportes se muestran en diferentes etapas y mediante distintos tipos de resultados.

2.5.1 Diferencias entre las tres disciplinas

Las diferencias entre Data Analytics, Data Science y Data Engineering están en su propósito que tienen como meta cada disciplina y en las actividades que realiza para alcanzar sus objetivos. Aunque las tres trabajan con datos, sus responsabilidades se concentran en aspectos distintos del proceso.

Data Engineering se enfoca en la infraestructura y en los procesos que se necesitan para que los datos puedan utilizarse de manera confiable. Sus trabajadores diseñan, construyen y mantienen canalizaciones de datos, integran información que viene de diferentes fuentes y establecen mecanismos para el almacenamiento, transformación y distribución. Por esta razón, su trabajo se relaciona principalmente con la arquitectura de datos, la automatización de procesos, la calidad de la información y la disponibilidad de los sistemas.

Data Analytics se concentra en examinar los datos disponibles, aprender de las situaciones, identificar patrones o tendencias, responder preguntas específicas de una organización. Los analistas de datos utilizan consultas, herramientas estadísticas y técnicas de visualización para leer la información y comunicar los resultados mediante informes de los procesos, identificar oportunidades de mejora y fundamentar decisiones con evidencia.

Por otra parte, Data Science tiene como propósito extraer conocimiento mediante métodos analíticos, estadísticos y computacionales que dejan meterse en problemas de mayor de complejidad. Los científicos de datos pueden desarrollar modelos de aprendizaje automático, hacer predicciones, clasificar información y reconocer patrones que no son evidentes mediante un análisis convencional. Además, evalúan el rendimiento de los sistemas y, cuando corresponde, participan en su implementación y mantenimiento.

Sus diferencias se reflejan también en los resultados que produce cada disciplina. Data Engineering genera infraestructuras, canalizaciones y conjuntos de datos preparados para su utilización. Data Analytics produce informes, visualizaciones, indicadores y recomendaciones orientadas a la toma de decisiones. Data Science, por su parte, puede generar modelos predictivos,

algoritmos de clasificación, sistemas de recomendación y evaluaciones estadísticas que permiten anticipar comportamientos o automatizar determinadas tareas.

2.5.2 Similitudes entre las tres disciplinas

A pesar de las diferencias, Data Analytics, Data Science y Data Engineering comparten cosas que facilitan la colaboración entre sus profesionales. En primer lugar, las tres trabajas con datos y buscan aprovechar estos para mejorar procesos, resolver problemas o necesidades de organización.

Otra similitud, corresponde a la importancia de la calidad de los datos. Aunque las responsabilidades, consistente y adecuada para el propósito del proyecto. Data Engineering se encarga de la construcción de procesos de validación, integración y transformación; Data Analytics revisa la información para identificar errores o inconsistencias que puedan afectar resultados; y Data Science necesita datos apropiados para entrenar y evaluar sus modelos. En consecuencia, los errores que pueden haber pueden afectar tanto los resultados analíticos como el funcionamiento de los modelos predictivos.

También comparten el uso de lenguajes de programación y bases de datos, aunque por supuesto su aplicación depende de las necesidades de cada actividad. Comparten la necesidad de comprender el contexto del problema que se desea resolver. Antes de hacer una infraestructura, preparar un informe o hacer un modelo predictivo, es necesario identificar qué datos requiere, cúal es el origen del problema y cómo se usarán los resultados.

Finalmente, estas disciplinas requieren procesos de documentación, supervisión y mejora continua. Los ingenieros de datos deben verificar que todo funcione correctamente, los analistas tienen que comprobar que sus consultas e informes representen bien la información; los científicos de datos deben evaluar los modelos y ver su rendimiento. Por lo tanto, las tres áreas comparten el compromiso de producir resultados útiles, comprensibles y confiables.

2.5.3 Herramientas compartidas y características

Las herramientas pueden coincidir debido a que las tres disciplinas necesitan acceder,procesar y utilizar datos. Sin embargo, el que compartan la tecnología no significa que lo hagan por el mismo objetivo. La herramienta depende del problema, el volumen de información y las actividades que se deben desarrollar.

Entre las herramientas compartidas se encuentra SQL, utilizado para consultar y manipular datos almacenados en sistemas de bases de datos. En Data Engineering permite transformar información y controlar su movimiento entre diferentes estructuras; en Data Analytics facilita la extracción, combinación y exploración de registros para elaborar informes; y en Data Science permite obtener los conjuntos de datos necesarios para realizar análisis estadísticos y entrenar modelos.

Python constituye otra tecnología importante para las tres disciplinas. Los ingenieros de datos pueden utilizarlo para automatizar tareas, integrar fuentes y construir canalizaciones. Los analistas lo emplean para limpiar información, realizar cálculos y generar visualizaciones, mientras que los científicos de datos lo utilizan para el análisis estadístico, la experimentación y el desarrollo de modelos de aprendizaje automático.

Otros sistemas como PostgreSQL, MySQL, SQL Server y Oracle permiten gestionar bases de datos relacionales, mientras que plataformas como Google BigQuery y Snowflake se emplean para almacenar y consultar grandes volúmenes de información destinados al análisis. La participación de cada disciplina depende de las necesidades del proyecto y de la arquitectura tecnológica de la organización.

2.5.4 Participación dentro del ciclo de vida de los datos

Este ciclo de vida de los datos tiene diferentes etapas que nos dejan obtener información desde las fuentes originales, para poder utilizarla para responder preguntas o resolver problemas. Dentro de este proceso, Data Engineering, Data Analytics y Data Science desempeñan funciones complementarias.

En una primera etapa, Data Engineering participa en la recopilación e integración de datos provenientes de bases de datos, aplicaciones, archivos, servicios web y otras fuentes. Posteriormente, desarrolla procesos de transformación y validación para corregir inconsistencias, organizar los registros y almacenar la información en estructuras apropiadas. Estas actividades permiten que los datos estén disponibles y sean accesibles para los profesionales que los necesitan.

Una vez que los datos se encuentran preparados, Data Analytics puede utilizarlos para explorar la información, calcular indicadores, identificar tendencias y elaborar informes. Mediante

el análisis descriptivo y diagnóstico, ayudan a comprender qué ha sucedido y cuáles factores podrían estar relacionados con determinados resultados. Asimismo, las conclusiones permiten identificar nuevas preguntas que podrían requerir investigaciones adicionales.

Data Science también utiliza los datos preparados para realizar análisis estadísticos más complejos y desarrollar modelos predictivos. Sus profesionales seleccionan las variables pertinentes, entrenan algoritmos, evalúan su rendimiento y determinan si los resultados cumplen con los objetivos establecidos. Cuando los modelos se incorporan a los sistemas de una organización, es necesario tenerlos bajo vigilancia y actualizarlos según cambien las condiciones y los datos disponibles.

La relación entre las tres disciplinas no debe entenderse como una secuencia estrictamente lineal. En la práctica, los resultados de una etapa pueden generar nuevas necesidades en las demás. Por ejemplo, si un científico de datos determina que necesita una variable adicional para mejorar la precisión de un modelo, puede solicitar al ingeniero de datos que incorpore una nueva fuente de información. Del mismo modo, si un analista identifica inconsistencias en un informe, puede ser necesario revisar los procesos que generaron o transformaron los datos.

Por tanto, el ciclo de vida de los datos funciona como un proceso iterativo en el que la preparación, el análisis, el modelado y la supervisión se retroalimentan para así llegar a un resultado más satisfactorio para la organización o empresa en la que se esté trabajando. La colaboración entre las disciplinas permite mejorar la calidad de los datos, la confiabilidad de los resultados y la utilidad de las soluciones desarrolladas.

2.5.5 Puntos de traslape entre los roles

Aunque Data Analytics, Data Science y Data Engineering poseen responsabilidades diferenciadas, existen puntos de traslape por donde el trabajo de datos requiere conocimientos y experiencias compartidas por que dependiendo del tamaño y las necesidades de una organización, un mismo trabajador puede asumir tareas que están en más de una disciplina.

Un punto de traslape es en la preparación y limpieza de datos, los ingenieros de datos suelen hacer procesos automatizados para integrar, validar, y transformar información. Sin embargo, los analistas también pueden limpiar datos para realizar una consulta específica, mientras que los

científicos de datos hacen conjuntos de datos que utilizarán durante el entrenamiento y evaluación de modelos.

Otro punto de traslape es en el análisis de datos. Tanto los analistas como los científicos pueden utilizar estadísticas,gráficos, y medidas de resumen para identificar patrones y relaciones entre variables. Pero, los Data Analytics suelen orientar esto al negocio y comunicar resultados, mientras que Data Science puede usarlas para hacer hipótesis, seleccionar variables y establecer las bases de un modelo predictivo.

Las tres disciplinas pueden participar en la evaluación de calidad de los datos. Data Engineering establece controles y validaciones durante los procesos de integración; Data Analytics comprueba si la información resulta adecuada para los indicadores que desea calcular; y Data Science analiza si los datos son representativos y apropiados para entrenar modelos. Esto demuestra que la calidad no depende de una etapa exclusivamente sino de la participación de todas las partes. En consecuencia, los puntos de traslape no representan una repetición innecesaria de funciones. Todo lo contrario, pueden fortalecer el trabajo cuando existe una partición clara de responsabilidades, una adecuada comunicación y criterios claros para evaluar resultados.

2.5.6 Fricciones entre los roles

A pesar de que las tres disciplinas buscan aprovechar los datos, pueden presentarse dificultades de coordinación cuando sus objetivos, prioridades o formas de trabajo no se encuentran alineados. Estas fricciones pueden afectar la calidad de los resultados, retrasar los proyectos y generar trabajo adicional. Por esta razón, comprenderlas permite identificar la importancia de establecer responsabilidades claras y mecanismos de colaboración.

Una primera fuente de fricción se relaciona con la calidad y disponibilidad de los datos. Los analistas y científicos de datos pueden necesitar información limpia, completa y actualizada para cumplir con sus tareas. Sin embargo, los datos de origen pueden presentar valores faltantes, duplicados, formatos diferentes o errores. Si los ingenieros de datos no conocen las necesidades específicas de quienes consumirán la información, los conjuntos de datos entregados podrían requerir modificaciones adicionales. De igual manera, si los requerimientos cambian durante el proyecto sin una comunicación adecuada, puede ser necesario reconstruir procesos que ya se encontraban implementados.

Una segunda dificultad corresponde a las diferencias entre las prioridades de cada disciplina. Data Engineering suele concentrarse en la estabilidad, eficiencia, seguridad y escalabilidad de los sistemas. Data Analytics prioriza la disponibilidad de información útil y la entrega oportuna de informes, mientras que Data Science puede requerir tiempo adicional para experimentar, comparar algoritmos y mejorar el rendimiento de los modelos. Estas prioridades pueden entrar en conflicto cuando, por ejemplo, se solicita una nueva fuente de datos de manera urgente, pero su integración requiere modificaciones importantes en la infraestructura.

También pueden surgir desacuerdos relacionados con las definiciones y la interpretación de los indicadores. Si un analista y un científico de datos utilizan criterios diferentes para calcular una variable, los resultados pueden ser inconsistentes. Del mismo modo, si los datos se transforman sin documentar los cambios realizados, otros profesionales podrían interpretar incorrectamente la información o reproducir resultados diferentes. Para evitar esta situación, resulta importante establecer definiciones compartidas, documentar las transformaciones y mantener trazabilidad sobre el origen de los datos.

Otra fuente de fricción se presenta durante la implementación de modelos predictivos. Un científico de datos puede desarrollar un modelo que funciona correctamente durante las pruebas, pero cuya ejecución en producción requiere recursos, integraciones o mecanismos de supervisión que no se habían contemplado inicialmente. En este caso, el ingeniero de datos y los profesionales responsables de la infraestructura deben colaborar para determinar si la solución puede ejecutarse de forma estable, segura y eficiente. Asimismo, los resultados del modelo deben ser comprensibles para los analistas y las personas responsables de tomar decisiones.

Finalmente, pueden existir dificultades de comunicación entre los profesionales técnicos y los responsables del negocio. Un resultado estadístico o un modelo con un buen rendimiento técnico no garantiza, por sí solo, que la solución responda a una necesidad real. Por ello, es necesario que los requerimientos se comuniquen de manera clara y que las limitaciones, los costos y los beneficios de cada propuesta sean comprendidos por las partes involucradas.

Para reducir estas fricciones, las organizaciones pueden establecer responsabilidades bien definidas, utilizar documentación compartida, implementar controles de calidad, automatizar pruebas y mantener una comunicación constante entre los equipos. Además, metodologías de

trabajo como CRISP-DM y enfoques de colaboración y automatización como DataOps y MLOps pueden contribuir a organizar las actividades, supervisar los procesos y facilitar la entrega de soluciones confiables.

En síntesis, las diferencias entre Data Analytics, Data Science y Data Engineering no impiden que exista colaboración entre ellas. Por el contrario, la especialización de cada disciplina permite abordar diferentes necesidades de un proyecto, siempre que se establezcan objetivos comunes y mecanismos adecuados de coordinación.

2.5.7 Cuadro comparativo

Tabla 1

Comparación entre Data Analytics, Data Science y Data Engineering

Criterio	Data Analytics	Data Science	Data Engineering
Objetivo	Analizar e interpretar datos para obtener información útil que facilite la toma de decisiones.	Extraer conocimiento, identificar patrones, desarrollar modelos estadísticos y predictivos para resolver problemas complejos.	Diseñar, construir y mantener infraestructuras y procesos que permitan disponer de datos confiables y organizados.

Criterio	Data Analytics	Data Science	Data Engineering
Tipo de preguntas que responde	¿Qué sucedió?, ¿por qué sucedió?, ¿qué tendencias se identifican? y ¿qué acciones se pueden recomendar?	¿Qué podría suceder?, ¿qué patrones pueden descubrirse? y ¿cómo se pueden predecir o clasificar resultados?	¿De dónde provienen los datos?, ¿cómo se pueden integrar, transformar y almacenar?, ¿cómo garantizar su calidad y disponibilidad?
Responsabilidades principales	Recopilar, limpiar, explorar e interpretar datos; calcular indicadores; elaborar informes y visualizaciones; comunicar hallazgos y recomendaciones.	Preparar datos para el modelado; formular hipótesis; seleccionar y entrenar algoritmos; evaluar modelos; desarrollar soluciones predictivas y supervisar su rendimiento.	Integrar fuentes de información; desarrollar canalizaciones de datos; automatizar procesos; administrar sistemas de almacenamiento; validar la calidad y garantizar la disponibilidad de los datos.

Criterio	Data Analytics	Data Science	Data Engineering
Datos o entradas utilizadas	Datos estructurados y semiestructurados provenientes de bases de datos, archivos, encuestas, ventas y sistemas empresariales.	Datos estructurados, semiestructurados y no estructurados, históricos o actuales, que se utilizan para el análisis estadístico y el entrenamiento de modelos.	Datos en bruto procedentes de bases de datos, archivos, aplicaciones, API, dispositivos y otras fuentes de información.
Entregables	Informes, dashboards, indicadores clave de rendimiento (KPI), visualizaciones, consultas SQL, análisis descriptivos y recomendaciones para el negocio.	Modelos de aprendizaje automático, predicciones, algoritmos de clasificación, sistemas de recomendación, evaluaciones estadísticas y documentación técnica de modelos.	Canalizaciones de datos, procesos ETL y ELT, bases de datos integradas, almacenes de datos, procesos automatizados y conjuntos de datos preparados para su utilización.

Criterio	Data Analytics	Data Science	Data Engineering
Herramientas y tecnologías	SQL, Excel, Google Sheets, Python, Pandas, Power BI, Tableau y herramientas estadísticas.	Python, R, SQL, Pandas, NumPy, Scikit-learn, XGBoost, Matplotlib, MLflow y herramientas de procesamiento distribuido.	SQL, Python, PostgreSQL, MySQL, Oracle, Apache Spark, Apache Airflow, servicios de almacenamiento en la nube y herramientas para procesos ETL y ELT.
Procesos o metodologías	Extracción y preparación de datos, análisis descriptivo y diagnóstico, análisis predictivo y prescriptivo, visualización e informes. Puede utilizar CRISP-DM para organizar proyectos analíticos.	Comprensión del negocio, recopilación y preparación de datos, modelado, evaluación, despliegue y mantenimiento. Puede utilizar CRISP-DM, SEMMA, KDD y TDSP.	Extracción, integración, transformación, validación, almacenamiento y distribución de datos. Utiliza enfoques ETL, ELT, procesamiento por lotes, streaming y prácticas de DataOps.

Criterio	Data Analytics	Data Science	Data Engineering
Participación en el ciclo de vida de los datos	Utilizará datos preparados para analizarlos, interpretarlos y comunicar resultados que apoyen la toma de decisiones. Sus hallazgos pueden generar nuevas necesidades de información.	Utiliza los datos preparados para desarrollar y evaluar modelos, generar predicciones y convertir los resultados en soluciones que puedan integrarse en los sistemas de la organización.	Participa principalmente en la recopilación, integración, transformación y almacenamiento de los datos, además de mantener los procesos que permiten su disponibilidad para otras disciplinas.

3. Caso práctico

3.1 Conjunto de datos utilizado

Para el desarrollo del caso práctico se escogió el conjunto de datos Chicago Food Inspections, publicado por la Ciudad de Chicago. El conjunto contiene información relacionada con inspecciones sanitarias realizadas a establecimientos de alimentos.

El archivo fue descargado en formato CSV y se mantuvo sin modificaciones antes de ser cargado en la base de datos, con el objetivo de conservar el estado original de publicación. Esto permite posteriormente identificar y documentar los problemas de calidad existentes antes de realizar cualquier proceso de limpieza o transformación, tal como se solicita en la guía de la investigación.

El conjunto utilizado contiene 316.961 registros y 17 columnas. Las columnas presentes en el archivo son: INSPECTION_ID, DBA_NAME, AKA_NAME, LICENSE_NUMBER,

FACILITY_TYPE, RISK, ADDRESS, CITY, STATE, ZIP, INSPECTION_DATE, INSPECTION_TYPE, RESULTS, VIOLATIONS, LATITUDE, LONGITUDE y LOCATION.

3.2 Data Engineering

Carga de los datos en Oracle

La primera etapa del caso práctico corresponde a Data Engineering. En esta etapa se realizó la carga del conjunto de datos original dentro de un sistema gestor de bases de datos, utilizando Oracle Database y SQL Developer.

Para conservar los datos originales antes de cualquier transformación se creó una tabla denominada:

FOOD_INSPECTIONS_RAW.

El término “RAW” indica que esta tabla representa la versión inicial de los datos, es decir, los registros tal como fueron obtenidos desde el archivo CSV antes de aplicar procesos de limpieza.

Después de realizar la importación se verificó la cantidad de registros mediante la siguiente consulta:

```
SELECT COUNT(*)
FROM FOOD_INSPECTIONS_RAW;
```

El resultado obtenido fue de: 316.961 registros. Este valor permitió comprobar la cantidad de filas almacenadas en Oracle, aunque por sí solo no demuestra que las fechas, coordenadas y textos extensos se hayan importado correctamente. La primera consulta de sql/02profiling.sql permite repetir este conteo y contrastarlo con la cantidad de INSPECTION_ID distintos.

Decisiones tomadas durante la carga

Durante el proceso de importación fue necesario definir los tipos de datos adecuados para las columnas. Algunas variables requirieron un tratamiento particular debido a las características de la información almacenada.

La columna VIOLATIONS contiene descripciones extensas acerca de las infracciones encontradas durante las inspecciones. Inicialmente se intentó utilizar VARCHAR2(4000), sin

embargo, se encontraron registros que superaban este tamaño, alcanzando una longitud máxima de 12.706 caracteres. Por esta razón se decidió utilizar el tipo de dato CLOB, permitiendo almacenar textos de mayor longitud sin eliminar información. El perfilado confirmó 4.469 textos superiores a 4.000 caracteres.

Las columnas LATITUDE y LONGITUDE fueron almacenadas inicialmente como VARCHAR2(50) dentro de la tabla RAW. Esta decisión permitió conservar los valores originales durante la etapa de carga y dejar su conversión a un tipo numérico para el posterior proceso de limpieza y transformación.

La columna ZIP también fue almacenada como texto mediante VARCHAR2(20), debido a que representa un código postal y no un valor sobre el cual sea necesario realizar operaciones matemáticas.

La columna INSPECTION_DATE fue almacenada utilizando el tipo DATE. Durante la importación se especificó el formato: MM/DD/YYYY, debido a que las fechas del conjunto original se encuentran en formato estadounidense. La correspondencia con el CSV se confirmó para los ID 67757 y 2644019.

Estructura de la tabla RAW

La tabla inicial utilizada para almacenar los datos fue creada mediante la siguiente estructura:

```
CREATE TABLE FOOD_INSPECTIONS_RAW (
    INSPECTION_ID NUMBER(38),
    DBA_NAME VARCHAR2(255),
    AKA_NAME VARCHAR2(255),
    LICENSE_NUMBER NUMBER(38),
    FACILITY_TYPE VARCHAR2(255),
    RISK VARCHAR2(100),
    ADDRESS VARCHAR2(255),
    CITY VARCHAR2(100),
    STATE VARCHAR2(20),
    ZIP VARCHAR2(20),
    INSPECTION_DATE DATE,
    INSPECTION_TYPE VARCHAR2(255),
    RESULTS VARCHAR2(100),
    VIOLATIONS CLOB,
    LATITUDE VARCHAR2(50),
    LONGITUDE VARCHAR2(50),
    LOCATION VARCHAR2(255)
);
```

Perfilado inicial de los datos

El perfilado se realizó mediante 12 consultas SELECT ejecutadas en Oracle, sin modificar los registros. El script completo se conserva en sql/02profiling.sql y sus salidas en evidencias/perfilado_final/perfilado_resultados.txt.

Conteo general e identificadores

Se verificaron 316.961 registros y el mismo número de INSPECTION_ID distintos, sin identificadores NULL ni repetidos. Este control confirmó el volumen almacenado y la unicidad del identificador de cada inspección.

Valores NULL y textos con espacios

Se encontraron NULL en 12 de las 17 columnas. FACILITY_TYPE y AKA_NAME presentaron 5.357 y 2.426 valores faltantes, respectivamente. ADDRESS no presentó NULL, pero tuvo tres registros formados únicamente por espacios; por tanto, la ausencia de NULL no garantiza contenido útil.

Variables categóricas principales

RESULTS presentó siete categorías; Pass (164.074) y Fail (61.038) fueron las más frecuentes. RISK mostró los tres niveles de riesgo, además de 87 valores All y 87 NULL. FACILITY_TYPE e INSPECTION_TYPE registraron 527 y 110 valores distintos no nulos, respectivamente. Canvass fue el tipo de inspección más frecuente (163.611). Se observaron variantes de escritura, como BANQUET HALL/Banquet Hall y No Entry/NO ENTRY. El significado de All y las reglas de normalización permanecen pendientes.

Fechas de inspección

INSPECTION_DATE abarcó de 2010-01-04 a 2026-10-09, sin valores NULL. Las fechas de los ID 67757 y 2644019 coincidieron con las del CSV, respectivamente. La presentación en formato YYYY-MM-DD permitió corregir la interpretación previa del día y el mes.

Posibles duplicados de contenido

Se detectaron 104 grupos candidatos con INSPECTION_ID diferentes, coincidencia en los campos comparados e igual longitud de VIOLATIONS. La consulta no compara el texto completo del CLOB; estos grupos no constituyen duplicados exactos confirmados ni justifican eliminar registros.

Coordenadas geográficas

Los 315.900 valores no nulos de cada columna se convirtieron sin errores; LATITUDE y LONGITUDE tuvieron 1.061 faltantes cada una. Los rangos mostrados por SQL*Plus fueron de 41,6446701 a 42,0210642 para latitud y de -87,906874 a -87,525094 para longitud. No hubo valores fuera de -90 a 90 y -180 a 180, respectivamente. Esta validación de rangos generales no demuestra pertenencia exacta a Chicago.

Descripción de infracciones

VIOLATIONS presentó 89.410 NULL, cero textos vacíos o formados solo por espacios, una longitud máxima de 12.706 caracteres y 4.469 textos superiores a 4.000. Esto respalda el uso de CLOB para conservar descripciones extensas. Un NULL no demuestra ausencia de infracciones.

Licencias

LICENSE_NUMBER registró 19 NULL y 837 valores cero. Se mantuvieron sin cambios; su interpretación y tratamiento deberán justificarse antes de utilizar la licencia como identificador de establecimiento. El valor cero no se interpretó automáticamente como una licencia válida ni como un dato faltante.

Comparación antes y después

Aspecto	Antes: tabla original	Después: conjunto limpio
Fuente	Archivo CSV original	FOOD_INSPECTIONS_RAW
Tabla	FOOD_INSPECTIONS_RAW	CLEAN
Registros	316.961	316.961
Columnas	17	17
Valores nulos	NULL en 12 columnas; tres ADDRESS con solo espacios	3 ADDRESS pasaron a NULL; demás faltantes conservados
Duplicados por INSPECTION_ID	0	0; se conservaron todas las filas

Categorías	RESULTS: 7; RISK: tres niveles y All; FACILITY_TYPE: 527; INSPECTION_TYPE: 110	FACILITY_TYPE: 473; INSPECTION_TYPE: 98; RESULTS y RISK conservados
Fechas	2010-01-04 a 2026-10-09; sin fechas NULL	Mismo rango; fechas conservadas
Coordenadas	1.061 faltantes por columna; conversión correcta; 0 fuera de rango	NUMBER; 1.061 NULL; 0 fuera de rango
VIOLATIONS	Máximo: 12.706 caracteres; 4.469 textos >4.000; 89.410 NULL	CLOB; mismas longitudes y 89.410 NULL

Resultado de Data Engineering

El perfilado y la limpieza aprobada se completaron en Oracle. Se aplicó TRIM a ADDRESS, UPPER(TRIM()) a FACILITY_TYPE e INSPECTION_TYPE y la conversión explícita de coordenadas a NUMBER. CLEAN conserva las 316.961 filas; RAW permanece intacta. Las validaciones coincidieron con lo esperado y no se eliminaron candidatos a duplicados.

FOOD_INSPECTIONS_CLEAN entrega 17 columnas a Data Analytics y Data Science. El proceso se conserva en sql/03cleaning.sql y evidencias/limpieza/.

3.3 Data Analytics

Data Analytics utilizó únicamente FOOD_INSPECTIONS_CLEAN. Las siete consultas se ejecutaron en Oracle con GRUPO2 y sus resultados fueron verificados.

Pregunta de análisis: ¿Qué características de las inspecciones están asociadas con una mayor proporción de resultados Fail?

Consultas e indicadores: El script sql/04analytics.sql incluye dos verificaciones y cinco análisis: resultado general, RISK, INSPECTION_TYPE, FACILITY_TYPE y año. Se calcularon total de

registros, cantidad de Fail y porcentaje de Fail sobre todos los registros de cada grupo. Para los tipos de inspección y establecimiento se exigió un mínimo de 1.000 registros.

Hallazgos: 61.038 de 316.961 registros tienen RESULTS = 'Fail', equivalente al 19,26 % del total de registros. En RISK, Risk 3 (Low) presentó 20,89 % de Fail, Risk 1 (High) 19,14 % y Risk 2 (Medium) 19,05 %.

Entre las categorías con al menos 1.000 registros, COMPLAINT presentó la mayor proporción por tipo de inspección (33,23 %), seguida de LICENSE (29,75 %). Por establecimiento destacaron LIQUOR (31,51 %) y MOBILE FOOD PREPARER (25,04 %); RESTAURANT registró 18,64 %.

Evolución temporal: El porcentaje fluctuó entre 24,92 % en 2010 y 15,99 % en 2013; en 2025 fue 17,66 %. En 2026 fue 18,10 %, pero el año solo cubre hasta el 9 de octubre y no debe compararse como si tuviera la misma cobertura que los años completos.

Interpretación y limitaciones: Son asociaciones descriptivas y no demuestran que el riesgo u otra característica cause Fail. Una fila representa una inspección; un establecimiento puede aparecer varias veces. El denominador incluye las siete categorías de RESULTS, no únicamente Pass y Fail. NON-INSPECTION conserva 5.738 registros y 11 Fail; su significado ambiguo impide usarla para conclusiones sobre inspecciones efectivas. RISK conserva 87 All y 87 NULL, grupos pequeños que requieren cautela. No se eliminaron ni reclasificaron registros.

3.4 Data Science

Data Science utilizará los datos preparados durante Data Engineering y los resultados obtenidos mediante Data Analytics para desarrollar un análisis de mayor complejidad mediante técnicas estadísticas o de aprendizaje automático.

La implementación se realizará utilizando Python y herramientas destinadas a la preparación, modelado y evaluación de los datos.

Problema a resolver: [Pendiente]
Variable objetivo: [Pendiente]
Variables utilizadas: [Pendiente]

Modelo seleccionado: [Pendiente]

Resultados: [Pendiente]

Limitaciones: [Pendiente]

3.5 Encadenamiento de las tres disciplinas

En este apartado se busca dejar claro el proceso llevado a cabo por las tres disciplinas desde sus respectivas áreas de trabajo. Data Engineering recibe el archivo original, lo almacena en Oracle, analiza su calidad, realiza las transformaciones necesarias y produce datos preparados.

Posteriormente, Data Analytics recibe estos datos y los utiliza para realizar consultas, calcular indicadores, identificar tendencias y obtener hallazgos. Finalmente, Data Science recibe los datos preparados y el conocimiento obtenido durante el análisis para desarrollar y evaluar un modelo o técnica estadística.

Consecuencias de una etapa incorrecta

[Pendiente después de realizar las tres etapas.]

Importancia de la base de datos

[Pendiente después de finalizar el caso.]