01 EL MAPA

Del CSV a las respuestas

Una fila representa una inspección. Un establecimiento puede tener muchas inspecciones.

316.961
registros

17
columnas

1 fila
una inspección

RAW y CLEAN: 316.961 filas.
Limpieza ejecutada y verificada.

1 **CSV**
original
CONSERVADO

→

2 **Tabla RAW**
en Oracle
CARGADA

→

3 **Perfilado**
calidad revisada
EJECUTADO

→

4 **Limpieza**
transformar
EJECUTADA

→

5 **Datos**
preparados
CLEAN LISTA

→

6 **Analytics**
analizar
PENDIENTE

→

7 **Science**
modelar
PENDIENTE

RAW intacta → FOOD_INSPECTIONS_CLEAN · 17 columnas · Todas las filas conservadas

Engineering

RECIBE
CSV original

ENTREGA ESPERADA
CLEAN + evidencia verificada

CLEAN verificada

Analytics

RECIBE
Datos preparados

ENTREGA ESPERADA
Indicadores + interpretación

Salida práctica aún pendiente

Science

RECIBE
Datos preparados + pregunta

ENTREGA ESPERADA
Modelo evaluado + limitaciones

Salida práctica aún pendiente

02 QUÉ REVISAMOS

Perfilado = revisar antes de cambiar

El perfilado justificó las reglas aprobadas. La limpieza se aplicó sobre una tabla nueva.

1 ¿Cuántas filas y cuántos ID?

```
SELECT COUNT(*) AS FILAS,
 COUNT(DISTINCT INSPECTION_ID) AS ID_DISTINTOS,
 COUNT(*) - COUNT(INSPECTION_ID) AS ID_NULOS
FROM FOOD_INSPECTIONS_RAW;
```

Oracle: 316.961 filas y 316.961 ID distintos; sin ID NULL ni repetidos. DISTINCT cuenta ID diferentes.

2 ¿Hay contenido?

NULL ≠ [ ]

RAW: 3 con espacios → CLEAN: 3 NULL.

Categorías: antes → después

527 → 473 **110 → 98**

FACILITY_TYPE / INSPECTION_TYPE.
Se aplicó UPPER(TRIM()); RISK=All se conserva.

3 y 4 ¿Las fechas coinciden?

```
SELECT TO_CHAR(MIN(INSPECTION_DATE),
 'YYYY-MM-DD') AS MINIMA,
 TO_CHAR(MAX(INSPECTION_DATE),
 'YYYY-MM-DD') AS MAXIMA
FROM FOOD_INSPECTIONS_RAW;
```

Oracle y CSV coinciden (consulta 4):
67757 → 2010-01-04 · 2644019 → 2026-10-09
Rango confirmado; sin fechas NULL.

9 ¿Se repite contenido?

ID A ≠ ID B
Los campos y la longitud pueden coincidir.

104 grupos candidatos; no confirmados.

12 ¿La licencia falta?

NULL ≠ 0

Oracle: 19 NULL y 837 licencias con valor 0.

03 CÓDIGO QUE HAY QUE DEFENDER

Tres detalles que cambian el diagnóstico

Fragmentos para estudiar. Scripts completos: 02profiling.sql y 03cleaning.sql.

1 Coordenadas como números

03cleaning.sql

41,80 ⟶ **41.80**

Ejemplo didáctico: coma decimal → punto.
La conversión se probó en todos los valores no nulos.

```
TO_NUMBER(REPLACE(TRIM(LATITUDE), ',', '.'),
 '999D999999999999999',
 'NLS_NUMERIC_CHARACTERS=''.,''')
```

1.061 faltantes por columna.
0 latitudes y 0 longitudes fuera de rango.

CLEAN: coordenadas NUMBER; rangos conservados.

2 Medir todo el texto

Consulta 11

```
LENGTH(VIOLATIONS)
```

12.706 caracteres máximos (Oracle)

4.469 textos superan 4.000 caracteres.

89.410 NULL · 0 vacíos o solo espacios.

3 Normalizar sin perder filas

03cleaning.sql

```
UPPER(TRIM(FACILITY_TYPE))
```

Misma regla en INSPECTION_TYPE.
ADDRESS usa TRIM: solo espacios → NULL.

316.961 filas conservadas. Ningún candidato eliminado.

RESULTADOS VERIFICADOS EN ORACLE

04 ENSAYAR Y EXPONER

Contar la historia con evidencia

Reparto sugerido: cada persona guía un bloque; las cuatro deben entender el recorrido completo.

INTEGRANTE 1

Origen y carga

ZIP y coordenadas: texto.

VIOLATIONS: CLOB.
Fechas: DATE.

Mostrar: flujo + tipos.

INTEGRANTE 2

Calidad

TRIM y UPPER(TRIM()).

527 → 473 y 110 → 98 categorías.

Mostrar: resumen + ejemplo.

INTEGRANTE 3

Código clave

ID único y contenido repetido.

CLOB, decimales y rangos.

Mostrar: código + salida.

INTEGRANTE 4

Evidencia y cierre

CLEAN lista; RAW intacta.

Qué reciben Analytics y Science.

Mostrar: estado + pendientes.

Demostración breve en Oracle

2 a 4 → 5 → 6 a 8

03cleaning.sql: ejecutar solo las consultas de validación.
Filas y categorías → coordenadas → CLOB y tipos.

Tres ideas que no debemos confundir

ID único no descarta contenido repetido.
VIOLATIONS NULL no prueba ausencia de infracciones.
Rango geográfico válido no prueba ubicación en Chicago.

Siguiente: Analytics

Recibe: FOOD_INSPECTIONS_CLEAN.

Pendiente: definir preguntas de análisis y consultas.

Entregará: indicadores e interpretación.

Evidencia de limpieza: evidencias/limpieza/.